



Universidade Federal de Itajubá - *campus* de Itabira
Instituto de Ciências Tecnológicas

ENRIQUECIMENTO DE PROMPTS DE IA GENERATIVA: UMA ABORDAGEM BASEADA EM ONTOLOGIAS E LINGUAGEM NATURAL

PEDRO HENRIQUE AZEVEDO DO PRADO

Itabira MG
2025

PEDRO HENRIQUE AZEVEDO DO PRADO

ENRIQUECIMENTO DE PROMPTS DE IA GENERATIVA: UMA ABORDAGEM BASEADA EM ONTOLOGIAS E LINGUAGEM NATURAL

Trabalho de Conclusão de Curso apresentado ao
Curso de Engenharia de Computação da Universi-
dade Federal de Itajubá - *campus* de Itabira como
parte dos requisitos necessários para a obtenção do
grau em Bacharel em Engenharia de Computação.

Orientador: Eduarbo Ribeiro Felipe

Coorientador: Fernanda Farinelli

Itabira - MG
25 de junho de 2025

Agradecimentos

À conclusão deste trabalho, agradeço primeiramente à minha família, pelo apoio incondicional, pelos sacrifícios que tornaram possível a realização deste sonho e pela constante motivação para que eu me superasse. Em especial, à minha mãe, por ser meu pilar de sustentação e por ensinar, na prática, a perseverança e a resiliência; e ao meu pai, que, embora não tenha podido acompanhar a conclusão desta jornada de graduação, sempre me transmitiu a convicção de que determinação e trabalho duro são essenciais para o sucesso. À minha namorada, por ter estado ao meu lado em todos esses anos, sendo uma fonte contínua de motivação e inspiração.

Um agradecimento especial aos amigos da República Cálice, local de convivência durante a graduação, onde tive a oportunidade de construir laços de amizade que se tornaram uma verdadeira família, essencial para meu acolhimento e desenvolvimento pessoal.

Agradeço também aos meus orientadores, pelo acompanhamento próximo, pela orientação dedicada e pelo apoio essencial que garantiram o progresso contínuo deste trabalho.

Finalmente, à Universidade Federal de Itajubá (UNIFEI) e a todos os professores, por proporcionarem um ambiente de aprendizado enriquecedor e um suporte acadêmico fundamental que tornaram a realização deste trabalho possível.

Resumo

A crescente onipresença da interação homem-computador, impulsionada por avanços em inteligência artificial generativa como o ChatGPT, destaca a importância da engenharia de *prompt* para interações eficazes. Contudo, usuários frequentemente enfrentam dificuldades em formular *prompts* claros e precisos, resultando em respostas subótimas da IA. Este projeto propõe um método de expansão de consultas (*Query Expansion*) que aborda essa problemática, utilizando Processamento de Linguagem Natural (PLN) e a ontologia MFOEM, especializada no domínio das emoções humanas, como base de conhecimento para enriquecer *prompts* textuais. Os resultados demonstraram a viabilidade da abordagem, com ganhos mensuráveis na similaridade semântica entre *prompts* e respostas da IA, e evidenciaram a capacidade do sistema de lidar eficazmente com *prompts* mal formulados. Objetiva-se, assim, promover uma comunicação mais precisa e eficiente entre humanos e sistemas de IA generativa.

Palavras-chave: Engenharia de *Prompt*, Expansão de Consultas, Processamento de Linguagem Natural, Ontologias, Interação Humano-Computador, IA Generativa.

Abstract

The increasing omnipresence of human-computer interaction, driven by advances in generative artificial intelligence (AI) like ChatGPT, highlights the importance of prompt engineering for effective interactions. However, users often face difficulties in formulating clear and precise prompts, leading to suboptimal AI responses. This project proposes a Query Expansion method that addresses this issue, utilizing Natural Language Processing (NLP) and the MFOEM ontology, specialized in the domain of human emotions, as a knowledge base to enrich textual prompts. Results demonstrated the approach's feasibility, with measurable gains in semantic similarity between prompts and AI responses, and evinced the system's ability to effectively handle ill-formed prompts. The aim is thus to promote more precise and efficient communication between humans and generative AI systems.

Keywords: Prompt Engineering, Query Expansion, Natural Language Processing, Ontologies, Human-Computer Interaction, Generative AI.

Lista de figuras

Figura 1 – Diagrama representativo da interação entre os sistemas.	26
Figura 2 – Diagrama de funcionamento do <i>back-end</i>	33
Figura 3 – Conjunto de frases genéricas criado para adicionar novos conteúdos ao <i>prompt</i> original mantendo relevância com os termos encontrados na ontologia.	36
Figura 4 – Trecho de código que configura a rota <code>/calculate_similarity</code> no <i>Prompt Controller</i>	37
Figura 5 – Trecho da ontologia em visualização <i>OntoGraf</i>	38
Figura 6 – Tela inicial do protótipo, com o campo de entrada de <i>prompt</i> e o seletor de precisão.	41
Figura 7 – Ambientes de teste configurados no Gmail para isolar o histórico de <i>prompts</i>	43
Figura 8 – Configuração do ChatGPT com “Memória” desativada, garantindo independência entre requisições.	44
Figura 9 – Fluxograma seguido para execução dos testes.	45
Figura 10 – Diagrama representativo dos módulos que compõem o <i>back-end</i> . . .	48
Figura 11 – Estrutura de diretórios do repositório <i>back-end</i>	49
Figura 12 – Página inicial da documentação construída para o <i>back-end</i>	50
Figura 13 – Exibição do <i>prompt</i> enriquecido.	51
Figura 14 – Visualização opcional de detalhes avançados.	52
Figura 15 – Envio do <i>prompt</i> original ao ChatGPT e resposta gerada.	53
Figura 16 – Envio do <i>prompt</i> expandido ao ChatGPT e resposta gerada.	54
Figura 17 – Envio do <i>prompt</i> original e sua resposta à API de similaridade semântica.	55
Figura 18 – Envio do <i>prompt</i> expandido e sua resposta à API de similaridade semântica.	55

Lista de tabelas

Tabela 1 – *Prompts* bem formulados em suas formas originais e expandidas . . . 57

Tabela 2 – *Prompts* mal formulados em suas formas originais e expandidas . . . 59

Tabela 3 – Comparação dos resultados obtidos por *prompt* 62

Lista de abreviaturas e siglas

ACM	Association for Computing Machinery
AI	Arquitetura da Informação
ASGI	Asynchronous Server Gateway Interface
BERT	Bidirectional Encoder Representations from Transformers
BFO	Basic Formal Ontology
CC	Ciência da Computação
CDNO	Compositional Dietary Nutrition Ontology
CI	Ciência da Informação
CNNs	Convolutional Neural Networks
CVDO	Cardiovascular Disease Ontology
DOID	Human Disease Ontology
EVALI	E-cigarette or Vaping Product Use-Associated Lung Injury
GANs	Generative Adversarial Networks
GPT	Generative Pre-trained Transformer
GPT-2	Generative Pre-trained Transformer 2
GPT-3	Generative Pre-trained Transformer 3
GPT-4	Generative Pre-trained Transformer 4
HTTP	Hypertext Transfer Protocol
IA	Inteligência Artificial

IHC	Interação Homem-Computador
IR	Information Retrieval
MFOEM	Emotion Ontology
MHP	Modelo do Processamento Humano
NER	Named Entity Recognition
NLTK	Natural Language Toolkit
OBO	Open Biological and Biomedical Ontologies
OBPX	Ontology Based Prompt Expander
OGMS	Ontology for General Medical Science
ONTOBRAS	Seminário Brasileiro de Pesquisa em Ontologias
OpenAI	Open Artificial Intelligence
OWL	Ontology Web Language
PLN	Processamento de Linguagem Natural
PMBOK	Project Management Body of Knowledge
QE	Query Expansion
RDF	Resource Description Framework
REST	Representational State Transfer
RNNs	Recurrent Neural Networks
SBERT	Sentence-BERT
SNOMED CT	Systematized Nomenclature of Medicine—Clinical Terms
SOLID	Single Responsibility Principle, Open/Closed Principle, Liskov Substitution Principle, Interface Segregation Principle, Dependency Inversion Principle

TCC	Trabalho de Conclusão de Curso
USE	Universal Sentence Encoder
UX	User Experience
WSGI	Web Server Gateway Interface

Sumário

1	INTRODUÇÃO	1
1.1	Considerações Iniciais	1
1.2	Objetivos	3
1.3	Justificativa	4
1.4	Estrutura da Monografia	5
2	REVISÃO BIBLIOGRÁFICA	6
2.1	Interação Homem-Computador (IHC)	6
2.1.1	Arquitetura da Informação	7
2.2	Inteligência Artificial	8
2.2.1	Inteligências Artificiais Generativas	9
2.2.2	Engenharia de <i>Prompt</i> (<i>Prompt Engineering</i>)	10
2.2.2.1	Técnicas de Engenharia de <i>Prompt</i>	11
2.3	Processamento de Linguagem Natural (PLN)	13
2.3.1	Aplicações do PLN em Inteligência Artificial Generativa.	13
2.3.2	Principais Tarefas de PLN	14
2.4	Ontologias	14
2.4.1	Definição e Estrutura das Ontologias	15
2.4.2	Abordagens de Ontologias em Diversas Disciplinas	16
2.4.3	Tipos de Ontologias e suas Aplicações	17
2.4.4	Ontologias e a Linguagem Natural	18
2.4.5	Ferramentas e Padrões de Ontologias	19
2.4.6	Realismo Ontológico e a <i>Basic Formal Ontology</i>	20
2.5	Expansão de Consultas (<i>Query Expansion</i>)	21
2.5.1	<i>Information Retrieval</i> (IR) e o Papel da Expansão de Consultas	21
2.5.2	Modelo Vetorial e o Conceito de Relevância	22
2.5.3	Técnicas de Expansão de Consultas	22
2.5.4	Técnicas de Substituição de Termos	23
2.5.5	Integração com Inteligências Artificiais Generativas	23

3	METODOLOGIA	25
3.1	Arquitetura Geral do Sistema	25
3.2	Desenvolvimento do Protótipo	28
3.2.1	Internacionalização do Protótipo	28
3.2.2	<i>Back-end</i>	28
3.2.2.1	Funcionamento do Fluxo	34
3.2.2.2	Geração de Novos Conteúdos	34
3.2.2.3	Lógica de <i>Thresholds</i> de Similaridade	36
3.2.2.4	Rota auxiliar para cálculo de similaridade semântica	37
3.2.2.5	Documentação Técnica do <i>Back-end</i>	37
3.2.3	Ontologia utilizada: MFOEM (<i>Emotion Ontology</i>)	38
3.2.4	<i>Front-end</i>	40
3.2.5	Metodologia de Validação da Solução Proposta	42
3.2.5.1	Preparação dos Dados	42
3.2.5.2	Ambientes de Validação Isolados	43
3.2.5.3	Execução dos Testes	44
3.2.5.4	Reprodutibilidade e Organização dos Resultados	46
4	RESULTADOS	47
4.1	<i>Back-end</i>	47
4.1.1	Documentação com <i>MKDocs</i>	49
4.2	<i>Front-end</i>	50
4.3	Resultados dos Testes	52
4.4	Análise Geral dos Resultados	56
5	DISCUSSÃO	64
6	CONCLUSÃO	67
	Referências	69

Apêndices	75
APÊNDICE A – PLANILHA DE DADOS DOS TESTES DE SI- MILARIDADE SEMÂNTICA	76
APÊNDICE B – REPOSITÓRIOS DO PROJETO NO GITHUB	77

1 Introdução

1.1 Considerações Iniciais

A interação entre humanos e computadores tem se tornado cada vez mais onipresente na sociedade, especialmente com a crescente digitalização da comunicação e do acesso à informação. Desde a década de 1970, a interação homem-computador consolidou-se como um campo de estudo dentro da ciência da computação, onde o foco é entender como melhorar a experiência do usuário ao interagir com sistemas digitais [MacKenzie, 2024]. Esse campo do conhecimento é fundamental para aprimorar a eficiência e usabilidade de uma ampla gama de ferramentas, que hoje vão desde plataformas de ensino e trabalho remoto até redes sociais e aplicativos de mensagens instantâneas.

Em 30 de novembro de 2022, a empresa de *software* *OpenAI* lançou uma ferramenta que marcou uma nova fase dessa interação: o ChatGPT¹. Este *software* é um programa de computador que tenta simular um ser humano na conversação com as pessoas, a exemplo da proposta de Alan Turing [Turing, 1950]. O sistema é baseado em inteligência artificial (IA) generativa, uma categoria de IA capaz de criar novos conteúdos, como texto, imagens, áudio e vídeo, a partir de exemplos ou instruções fornecidas. Em vez de apenas responder a perguntas ou executar comandos com base em informações pré-definidas, a IA generativa usa modelos complexos de aprendizado profundo para produzir respostas originais, criativas e contextualmente relevantes. Isso é possível porque a IA generativa, como o ChatGPT, é treinada com vastos conjuntos de dados, permitindo que compreenda a linguagem humana e gere respostas detalhadas em tempo real [OpenAI, 2022]. Sua rápida adoção global não apenas mostrou o potencial transformador dessas tecnologias, como também introduziu novas oportunidades e desafios para a comunicação entre humanos e máquinas. Entre as áreas que emergiram a partir desse desenvolvimento, destaca-se a engenharia de *prompt*, que se concentra na modelagem de instruções textuais fornecidas a IAs para garantir que as respostas geradas sejam coerentes e alinhadas com as expectativas do usuário [Mungoli, 2023].

¹ <https://openai.com/blog/chatgpt>. Acessado em: 04/09/2024.

A riqueza de descrições textuais em um *prompt* desempenha um papel crucial no desempenho de IAs generativas, como é o caso do ChatGPT. *Prompts* mais detalhados e informativos tendem a gerar respostas mais contextualmente precisas e alinhadas com as expectativas do usuário. Por outro lado, descrições sucintas ou ambíguas podem resultar em respostas superficiais ou incompletas. Isso ocorre porque, na engenharia de *prompt*, a qualidade das instruções textuais fornecidas à IA influencia diretamente sua capacidade de interpretar o contexto e processar a consulta de forma eficaz. Assim, um *prompt* bem formulado é capaz de guiar a IA para uma compreensão mais profunda da tarefa solicitada, enquanto *prompts* mal definidos podem dificultar o alcance do resultado esperado [Mungoli, 2023]. Nesse sentido, a engenharia de *prompt* visa otimizar essa interação, permitindo que usuários comuniquem suas intenções de forma clara e específica, potencializando a capacidade da IA de gerar respostas coerentes e úteis.

No entanto, um problema conhecido é a dificuldade do ser humano em se expressar de maneira eficaz por meio da linguagem natural escrita, especialmente ao criar *prompts* para IA. Embora o uso do Processamento de Linguagem Natural (PLN) tenha tornado a interação mais acessível, ainda há barreiras significativas na formulação de consultas que gerem resultados precisos [Oliveira Jr and El Khatib, 2024]. A habilidade de escrever um *prompt* claro e objetivo é um desafio para muitos usuários, o que pode resultar em respostas inadequadas ou desconexas por parte da IA. Portanto, esta pesquisa trabalha com o seguinte questionamento: como o uso de ontologias, alinhado ao Processamento de Linguagem Natural (PLN) e técnicas de expansão de *queries* ² pode aprimorar a formulação de *prompts* textuais, promovendo interações mais eficazes e alinhadas com os resultados esperados em sistemas de IA generativa?

Diante dessa problemática, a presente pesquisa propõe investigar soluções que aprimorem a formulação de *prompts* em IAs generativas, com base no uso de ontologias e técnicas de Processamento de Linguagem Natural (PLN). Essa abordagem busca não apenas superar as barreiras na interação homem-máquina, mas também contribuir para o avanço científico no campo da inteligência artificial. Na próxima seção, serão apresentados os objetivos deste trabalho, seguidos da justificativa que destaca sua relevância, originalidade e possíveis impactos práticos e acadêmicos."

Na seção a seguir, serão declarados os objetivos que compõem este trabalho,

² query expansion (tradução livre)

evidenciando suas metas e seu propósito.

1.2 Objetivos

O objetivo geral deste trabalho é investigar a viabilidade de enriquecer *prompts* para IAs generativas por meio da aplicação de técnicas de Processamento de Linguagem Natural (PLN), Expansão de *Queries* (QE) e uso de Ontologias. Para isso, será desenvolvido um protótipo funcional que permita ao usuário gerar *prompts* mais precisos e detalhados, utilizando um mecanismo de enriquecimento automático para aprimorar a interação com a IA e promover resultados mais coerentes e alinhados com as expectativas do usuário.

Para alcançar o objetivo geral deste trabalho, alguns objetivos específicos precisam ser explorados:

- Definir uma área de conhecimento específica para o protótipo, além de determinar a ontologia de domínio correspondente para cobrir essa área com eficácia.
- Selecionar uma linguagem de programação adequada para o desenvolvimento da interface *front-end* do protótipo, considerando critérios de usabilidade e integração com os demais componentes do sistema.
- Optar por uma linguagem de programação voltada para o tratamento dos dados no *back-end*, responsável por processar o *prompt* inicial, realizar a interpretação em Processamento de Linguagem Natural (PLN), consultar a ontologia, aplicar a Expansão de *Queries* (QE) e devolver o *prompt* enriquecido para a interface de usuário.
- Escolher um serviço de hospedagem adequado para disponibilizar o protótipo em desenvolvimento, seja de forma pública ou privada.
- Testar o protótipo com *prompts* reais e cotidianos, comparando as respostas geradas pelos *prompts* originais com as respostas resultantes dos *prompts* enriquecidos.

Na próxima seção, serão apresentados os motivos que justificam a relevância e a originalidade deste trabalho, destacando seus potenciais impactos acadêmicos e práticos.

1.3 Justificativa

Nos últimos anos, a interação com sistemas de inteligência artificial (IA) generativa, como o ChatGPT, tem ganhado destaque devido à sua capacidade de simular diálogos naturais com os usuários. No entanto, a eficácia dessas interações depende fortemente da qualidade dos *prompts* fornecidos. Muitos usuários encontram dificuldades em formular instruções claras e objetivas, o que compromete o potencial dessas ferramentas, gerando respostas imprecisas ou desconexas. Este problema não é apenas técnico, mas também cognitivo, visto que a clareza na expressão de intenções é desafiadora para muitos, especialmente em situações complexas ou contextos específicos.

Para abordar essa lacuna, o uso de ontologias computacionais desponta como uma solução promissora. Ontologias são artefatos formais que descrevem e organizam o conhecimento de um domínio específico de maneira sistemática e acessível, possibilitando que sistemas computacionais interpretem e processem informações com maior precisão [Staab and Studer, 2009, Almeida, 2020]. No contexto da IA generativa, as ontologias fornecem uma base sólida para alinhar os *prompts* com as capacidades do modelo, facilitando respostas mais coerentes e relevantes. Essa abordagem não apenas melhora a interação homem-máquina, mas também oferece subsídios para o desenvolvimento de soluções que reduzam os esforços cognitivos dos usuários ao interagir com sistemas inteligentes.

A relevância deste trabalho também reside na dependência crescente das tecnologias de IA em diversos setores, como educação, saúde, serviços ao cliente e desenvolvimento de software. Melhorar a qualidade da interação homem-computador nesses contextos pode aumentar a produtividade, reduzir mal-entendidos e ampliar o alcance dessas ferramentas para um público mais diversificado, independentemente de habilidades técnicas ou experiência prévia.

Além disso, ao explorar o enriquecimento de *prompts* por meio de ontologias, esta pesquisa contribui para o campo emergente da engenharia de *prompt*, buscando preencher lacunas na literatura científica. Embora técnicas de Processamento de Linguagem Natural (PLN) e Expansão de Consultas (QE) já tenham demonstrado seu valor em diversas aplicações, seu uso combinado com ontologias para aprimorar a formulação de *prompts* em IAs generativas ainda é pouco explorado. Esse trabalho, portanto, justifica-se tanto

por suas contribuições teóricas quanto práticas, com o objetivo de criar um método que potencialize a interação homem-máquina, promovendo avanços significativos na acessibilidade, eficiência e impacto social das tecnologias de IA.

1.4 Estrutura da Monografia

Esta monografia está organizada em seis seções, conforme descrito a seguir:

Na **Seção 1**, é apresentada a introdução do trabalho, abordando a motivação, o problema de pesquisa, os objetivos e a justificativa da proposta.

A **Seção 2** corresponde à revisão bibliográfica, onde são discutidos os principais conceitos teóricos relacionados ao tema, como ontologias, processamento de linguagem natural, engenharia de prompt, expansão de queries e interação humano-computador.

A **Seção 3** descreve a metodologia adotada para o desenvolvimento do trabalho, detalhando as decisões técnicas, o fluxo do sistema e as ferramentas utilizadas na implementação do protótipo.

A **Seção 4** reúne os resultados obtidos com a execução do protótipo, os testes realizados e a análise comparativa dos dados obtidos a partir dos *prompts* originais e enriquecidos.

Na **Seção 5**, são apresentadas reflexões sobre o processo de construção do trabalho, incluindo os desafios enfrentados, os aprendizados adquiridos e os ajustes realizados ao longo do caminho.

Por fim, a **Seção 6** traz a conclusão do trabalho, sintetizando as contribuições alcançadas, as limitações encontradas e as perspectivas para trabalhos futuros.

2 Revisão Bibliográfica

Esta seção tem como objetivo consolidar os fundamentos científicos e teóricos indispensáveis para o desenvolvimento deste trabalho. Ao apresentar conceitos-chave e avanços nas áreas de Interface Homem-Computador (IHC), Inteligências Artificiais Generativas, Processamento de Linguagem Natural (PLN), Ontologias, Engenharia de *Prompt* e Expansão de Consultas (*Query Expansion*), esta seção busca contextualizar as contribuições da pesquisa e situá-las em relação ao estado da arte. A análise destes temas proporciona uma importante base que fundamenta as escolhas metodológicas e técnicas, sendo crucial para embasar o protótipo proposto e justificar o uso de abordagens inovadoras no aprimoramento da interação e da precisão em sistemas de IA generativa.

2.1 Interação Homem-Computador (IHC)

A Interação Homem-Computador é um campo de estudo que examina como os humanos interagem com sistemas computacionais, com foco em desenvolver interfaces que melhorem a usabilidade, acessibilidade e experiência do usuário. Esse campo tem se tornado cada vez mais relevante com o avanço das tecnologias digitais e a integração de sistemas interativos em quase todos os aspectos da vida cotidiana. A clássica obra [Card et al., 1983] estabeleceu a base para a IHC, onde foi proposto o Modelo do Processamento Humano (MHP), que descreve como os usuários percebem, interpretam e respondem a estímulos em interfaces computacionais.

Outro trabalho fundamental na área é o livro [Shneiderman, 2010], onde o autor introduz as "regras de ouro do design de interfaces", que guiam o desenvolvimento de sistemas interativos com o objetivo de otimizar a eficiência e reduzir os erros dos usuários. Shneiderman argumenta que uma interface bem projetada deve seguir princípios como consistência, feedback, prevenção de erros e suporte ao aprendizado do usuário.

Além destes, outro trabalho significativo para a compreensão da IHC foi [Norman, 1988]. Nele, Norman descreve conceitos como a “visibilidade” e o “mapeamento” em design, que são essenciais para tornar os sistemas mais intuitivos. Ele destaca que o design

centrado no usuário deve considerar as limitações e capacidades cognitivas humanas, uma vez que interfaces intuitivas facilitam a adoção e o uso efetivo das tecnologias.

Mais recentemente, a IHC tem incorporado técnicas de usabilidade e experiência do usuário (*UX - User Experience*), abordando como o design de interfaces pode impactar a satisfação e o engajamento dos usuários. Na obra [Nielsen, 1994], Nielsen desenvolveu o conceito de heurísticas de usabilidade, que são princípios amplamente utilizados na avaliação de interfaces. Em conjunto com outros avanços na área, esses princípios buscam otimizar a IHC para tornar a interação mais eficiente, natural e adaptada às necessidades dos usuários.

Essas contribuições têm sido cruciais para a evolução da IHC, permitindo que interfaces de sistemas complexos, como inteligência artificial generativa, sejam projetadas de maneira que melhore a interação e minimize o esforço cognitivo dos usuários.

2.1.1 Arquitetura da Informação

A Arquitetura da Informação (AI) é um campo que visa organizar e estruturar as informações em interfaces digitais, de maneira que facilite o acesso e a navegabilidade do usuário. A AI se concentra na criação de sistemas informacionais que sejam intuitivos, organizados e fáceis de usar [Rosenfeld et al., 2015]. Os autores da obra descrevem a AI como o planejamento e design de estruturas informacionais, que incluem organização, rotulagem, navegação e sistemas de busca, ajudando a tornar a informação acessível e relevante para o usuário.

A relação entre IHC e AI é estreita, uma vez que a Arquitetura da Informação orienta o design da interface, buscando reduzir a carga cognitiva e aumentando a eficiência da interação. Morville, uma das figuras principais da AI, introduziu o conceito de "*findability*" (capacidade de encontrar informações) como uma das qualidades fundamentais de uma boa arquitetura de informação [Morville and Rosenfeld, 2005]. De acordo com o autor, interfaces bem estruturadas devem permitir ao usuário localizar informações e realizar suas tarefas de forma eficiente, o que é essencial em sistemas complexos, como plataformas de inteligência artificial generativa.

Além disso, na obra [Dillon, 2002], o autor discute que a Arquitetura da Informação deve ser desenvolvida com base nas necessidades e expectativas dos usuários, o que

implica em um design centrado no usuário. Em sistemas de IHC, essa abordagem ajuda a reduzir o tempo e o esforço necessários para que o usuário compreenda a interface e navegue por ela, o que é crucial para garantir uma experiência satisfatória e eficaz.

Esses aspectos fazem com que a Arquitetura da Informação seja uma peça-chave na IHC, proporcionando uma estrutura que guie o usuário e melhore a usabilidade da interface, especialmente em ambientes interativos complexos.

2.2 Inteligência Artificial

A Inteligência Artificial (IA) refere-se ao estudo e desenvolvimento de sistemas computacionais que buscam emular ou simular comportamentos inteligentes, baseados em regras e algoritmos predefinidos. Essa abordagem tem suas raízes na década de 1950 e é caracterizada por uma forte ênfase em tarefas específicas, utilizando modelos lógicos e simbólicos.

Uma das contribuições pioneiras para a IA clássica foi realizada por Alan Turing, cujos trabalhos sobre o "Teste de Turing" ajudaram a estabelecer os fundamentos para o desenvolvimento de máquinas capazes de simular inteligência humana. Em seu artigo seminal de 1950, Turing questiona se as máquinas podem pensar, propondo um teste baseado na capacidade de uma máquina enganar um interrogador humano, fazendo-o acreditar que está interagindo com outro ser humano [Turing, 1950].

Além disso, o desenvolvimento de sistemas especialistas na década de 1970 e 1980 desempenhou um papel crucial na IA clássica. Esses sistemas foram projetados para realizar tarefas de tomada de decisão com base em um conjunto de regras explícitas extraídas de especialistas humanos em um domínio específico. Edward Feigenbaum, um dos principais pesquisadores nessa área, foi fundamental na criação de sistemas como o DENDRAL e o MYCIN, que ajudaram a resolver problemas complexos de química e medicina, respectivamente [Feigenbaum, 1977].

John McCarthy, também um dos fundadores da IA, propôs a linguagem de programação LISP, que se tornou a linguagem dominante para o desenvolvimento de sistemas de IA clássicos devido à sua capacidade de manipular símbolos e expressar regras de forma eficiente. McCarthy definia a IA como "a ciência e engenharia de fazer máquinas

inteligentes” [McCarthy, 2006].

No entanto, apesar de seus sucessos, a IA clássica enfrentou dificuldades com a escalabilidade e flexibilidade. O modelo simbólico, altamente dependente de regras predefinidas, mostrou-se limitado em lidar com problemas mais complexos e dinâmicos do mundo real. Isso levou ao surgimento de abordagens alternativas, como as redes neurais, que posteriormente se destacaram na IA moderna, especialmente com o advento das IA generativas [Russell and Norvig, 2016].

2.2.1 Inteligências Artificiais Generativas

As Inteligências Artificiais Generativas (IAs Generativas) representam uma classe de sistemas de IA projetados para criar novos conteúdos, como texto, imagens, áudio e até vídeos, a partir de padrões aprendidos em grandes conjuntos de dados. Em vez de apenas reconhecer ou classificar informações, essas IAs podem gerar conteúdo novo, fazendo uso de modelos de aprendizado profundo, especialmente Redes Neurais Artificiais, que simulam parcialmente a estrutura de redes neurais humanas. Essa capacidade é o que diferencia as IAs generativas de outras abordagens mais tradicionais de inteligência artificial, como as IAs discriminativas, que apenas distinguem entre diferentes categorias de dados.

O conceito de IA generativa começou a ganhar destaque com a introdução dos Modelos Generativos Adversariais (GANs), propostos em [Goodfellow et al., 2014]. Os GANs utilizam duas redes neurais que competem entre si: uma rede geradora, que cria conteúdo, e uma rede discriminadora, que avalia a autenticidade desse conteúdo. Esse processo adversarial permite que o modelo aprenda a gerar dados realistas ao longo do tempo, contribuindo para avanços significativos na criação de imagens e vídeos realistas.

Outro avanço importante na IA generativa é o surgimento dos *Transformers*, modelo de arquitetura proposto em [Vaswani et al., 2017]. Os *Transformers* revolucionaram a área de Processamento de Linguagem Natural (PLN) ao introduzirem mecanismos de atenção, que permitem à IA focar em diferentes partes de um texto ao gerar respostas. Essa inovação possibilitou o desenvolvimento de modelos de linguagem poderosos, como o GPT-3, da OpenAI, e o seu sucessor, ChatGPT [Brown et al., 2020]. Esses modelos são treinados com bilhões de parâmetros, permitindo-lhes responder a perguntas, completar

frases, e até mesmo participar de conversas de forma convincente, imitando uma interação humana.

As IAs generativas apresentam um potencial transformador em diversas áreas, incluindo educação, arte, ciência e atendimento ao cliente. Contudo, elas também apresentam desafios e limitações. Bender et al., no artigo [Bender et al., 2021], discutem os riscos dessas IAs ao gerar informações factualmente incorretas ou enviesadas. Segundo os autores, o treinamento baseado em grandes volumes de dados pode introduzir vieses indesejados, uma vez que a IA replica padrões preexistentes sem compreensão real do contexto, o que pode resultar em conteúdo problemático ou inadequado.

A evolução das IAs generativas, especialmente com o desenvolvimento de modelos de linguagem como GPT-3¹, aponta para um futuro em que a interação homem-computador se tornará mais acessível e fluida. Produtos como o ChatGPT exemplificam a aplicação prática desses modelos em interfaces interativas, utilizando adaptações específicas do GPT-3 ou GPT-4 para permitir conversas naturalizadas com os usuários. No entanto, é fundamental que pesquisadores e desenvolvedores considerem as limitações e os riscos dessas tecnologias, especialmente no que diz respeito à confiabilidade e à ética na geração de conteúdo.

2.2.2 Engenharia de *Prompt* (*Prompt Engineering*)

A Engenharia de *Prompt* é uma área emergente no campo da inteligência artificial generativa, focada em desenvolver métodos para melhorar a interação entre usuários e modelos de linguagem, como o GPT-3 e o ChatGPT. Essa engenharia consiste em projetar e otimizar instruções textuais, ou "*prompts*", para que modelos de IA forneçam respostas que sejam relevantes e alinhadas com as expectativas dos usuários. Na obra [Reynolds and McDonell, 2021], os autores definem a engenharia de *prompt* como o processo de "ajustar o texto de entrada para maximizar a precisão e relevância da resposta gerada pelo modelo".

A importância desse campo de estudo reside no fato de que a formulação do *prompt* pode impactar diretamente a qualidade das respostas de uma IA. O desempenho dos modelos de linguagem é altamente sensível ao texto de entrada, uma vez que as

¹ GPT-3: <https://openai.com/research/language-unsupervised>. Acessado em: 28/09/2024

respostas geradas são baseadas no contexto e nas nuances da linguagem presente na instrução [Brown et al., 2020]. A engenharia de *prompt*, portanto, representa um avanço na interação homem-máquina, permitindo uma comunicação mais eficiente e reduzindo o esforço do usuário em ajustar sucessivamente as instruções para obter uma resposta satisfatória.

2.2.2.1 Técnicas de Engenharia de *Prompt*

Em [Reynolds and McDonell, 2021], os autores exploram uma série de técnicas utilizadas nas metodologias desse campo de estudo, incluindo *few-shot prompting* e *zero-shot prompting*. No *few-shot prompting*, o usuário fornece exemplos específicos para orientar o modelo sobre o tipo de resposta esperado. No *zero-shot prompting*, a instrução é escrita sem exemplos, exigindo que o modelo interprete a tarefa diretamente a partir da instrução textual. Além disso, técnicas como a encapsulação de contexto permitem que o *prompt* forneça informações adicionais que ajudem a IA a entender nuances e inferências implícitas, resultando em respostas mais completas e contextualmente adequadas [Li, 2023].

O uso de engenharia de *prompt* tem se expandido em áreas como atendimento ao cliente, educação e desenvolvimento de software, onde a precisão das respostas geradas pode impactar a experiência do usuário e a eficácia da aplicação da IA.

A engenharia de *prompt*, assim, torna-se uma ferramenta diferenciada para profissionais que desejam utilizar modelos de IA generativa em contextos reais, maximizando a precisão e a utilidade dos resultados gerados. A crescente popularidade de assistentes digitais e modelos de linguagem natural amplia a importância desse campo, exigindo mais pesquisas e desenvolvimento de novas técnicas para tornar as interações com IA mais acessíveis e eficientes.

Uma abordagem recente desta técnica é utilizada na plataforma leonardo.ai², focada em geração de imagens por IA através de *prompts* escritos. Nesta aplicação, existe a opção "*Enhance Prompt*", que aplica diretamente técnicas de engenharia de *prompt* ao analisar a instrução original e identificar oportunidades de aprimoramento. Com isso, a plataforma é capaz de expandir automaticamente os termos fornecidos pelo usuário,

² Leonardo.AI: <https://leonardo.ai/>. Acessado em: 02/10/2024.

fazendo uso de sinônimos, contextos relacionados e novos parâmetros que melhoram a precisão e adequação da resposta gerada pela IA.

Outro exemplo interessante de aplicação pode ser encontrado na plataforma Copy.ai³, que oferece uma ferramenta de geração de texto automatizada voltada para a criação de conteúdo de marketing. A plataforma utiliza técnicas de *prompt engineering* para otimizar a qualidade e relevância dos textos gerados. O usuário insere um *prompt* inicial e a ferramenta sugere várias opções de aprimoramento, como ajustes de tom, contexto e objetivo do texto. Isso é possível através da expansão de *queries*, onde o sistema gera variações e amplia o escopo da instrução original para produzir resultados mais alinhados com o propósito do usuário.

De forma similar, o DALL·E 2⁴ também utiliza técnicas de engenharia de *prompt* para gerar imagens a partir de descrições textuais. A plataforma oferece opções para expandir e detalhar o *prompt* original, como a funcionalidade "*inpainting*", que permite ao usuário adicionar detalhes à imagem gerada ou modificar partes específicas dela. Esse refinamento da instrução inicial não só melhora a qualidade da imagem gerada, mas também permite maior controle sobre o processo criativo, o que é fundamental para obter resultados mais personalizados e ajustados às necessidades do usuário.

Além disso, na área de desenvolvimento de software, plataformas como GitHub Copilot⁵ oferecem uma funcionalidade de auto-completar código baseada em IA, onde o usuário começa a escrever um trecho de código, e a ferramenta sugere o que escrever a seguir. Utilizando técnicas de *prompt engineering*, o modelo de IA consegue ajustar o código gerado ao contexto do código existente, sugerindo trechos adicionais, correções ou até mesmo otimizações. Isso é alcançado através da análise semântica do código, algo muito similar ao processo de expansão de consultas utilizado em sistemas de recuperação de informação, onde a consulta original é "expandida" para obter respostas mais completas e precisas.

Esses exemplos ilustram como a engenharia de *prompt* tem um papel fundamental na melhoria da qualidade e precisão das interações com sistemas de IA generativa, seja em contexto de geração de texto, imagens ou código. As técnicas de *prompt engineering* não

³ Copy.ai: <https://www.copy.ai/>. Acessado em: 02/10/2024.

⁴ DALL·E 2: <https://openai.com/dall-e-2>. Acessado em: 02/10/2024.

⁵ GitHub Copilot: <https://copilot.github.com/>. Acessado em: 04/10/2024.

só tornam a interação mais intuitiva e eficaz, como também permitem uma personalização profunda das respostas geradas, atendendo de maneira mais eficaz às necessidades e expectativas dos usuários.

2.3 Processamento de Linguagem Natural (PLN)

O Processamento de Linguagem Natural (PLN) é uma área interdisciplinar que visa capacitar computadores a compreender, interpretar e responder à linguagem humana de maneira eficiente. Esse campo tem suas raízes na interseção entre a linguística e a ciência da computação, com o objetivo de possibilitar interações mais naturais entre pessoas e máquinas. Em sua obra de referência, [Jurafsky and Martin, 2020], os autores definem o PLN como um conjunto de técnicas e modelos que permitem a manipulação da linguagem em forma textual e falada, e que vem ganhando relevância com o crescimento exponencial de dados disponíveis em linguagem natural.

A evolução do PLN foi impulsionada por métodos de aprendizado profundo, como redes neurais recorrentes (RNNs) e redes neurais convolucionais (CNNs), que possibilitaram avanços em tarefas complexas, incluindo tradução automática e análise de sentimentos. No entanto, o uso de *Transformers* representa um marco na área, graças à capacidade dessas redes de manipular e entender dependências contextuais de maneira mais eficiente. Este modelo utiliza mecanismos de atenção para identificar e analisar relacionamentos entre palavras no texto, e ele se destacou como a base para o desenvolvimento de modelos de linguagem de grande escala, como o GPT-3 e o BERT ⁶.

2.3.1 Aplicações do PLN em Inteligência Artificial Generativa.

Com o desenvolvimento de modelos de linguagem baseados em grandes quantidades de dados, como o GPT-3, o PLN possibilitou a criação de IAs generativas que são capazes de produzir respostas contextualmente coerentes e realistas a partir de *prompts* textuais. Em [Brown et al., 2020], é explicado que o treinamento em grandes conjuntos de dados permite que essas IAs aprendam padrões e nuances da linguagem humana, sendo

⁶ BERT: <https://research.google/pubs/bert-pre-training-of-deep-bidirectional-transformers-for-language-understanding/>. Acessado em: 04/10/2024.

capazes de responder perguntas, compor textos e até mesmo realizar tarefas específicas, como sumarização e classificação de textos.

2.3.2 Principais Tarefas de PLN

O PLN engloba diversas tarefas centrais que contribuem para o desenvolvimento de sistemas interativos e geradores de conteúdo. Entre essas tarefas estão:

- **Análise Sintática e Semântica:** Segundo [Manning and Schütze, 1999], a análise sintática permite que o sistema entenda a estrutura gramatical das frases, enquanto a análise semântica ajuda a extrair o significado das palavras no contexto.
- **Reconhecimento de Entidades Nomeadas (NER):** No estudo [Nadeau and Sekine, 2007], os autores explicam que o NER permite identificar e classificar nomes de entidades, como pessoas, locais e organizações, o que é essencial para a extração de informações e respostas precisas às perguntas.
- **Geração de Texto:** Com modelos como o GPT-2 e GPT-3, a geração de texto se tornou uma área de destaque, possibilitando a criação de conteúdo realista e coeso a partir de instruções simples fornecidas pelos usuários.

2.4 Ontologias

Esta subseção é fundamental para o desenvolvimento deste trabalho, pois fornece a base teórica e prática para a estruturação e organização do conhecimento em sistemas computacionais, especialmente no contexto da inteligência artificial e da interação homem-computador. Ontologias são artefatos computacionais que representam um conjunto de conceitos e as relações entre eles dentro de um domínio específico. Essa representação formalizada é essencial para possibilitar que sistemas de IA compreendam e processem informações de forma semântica, ampliando a capacidade desses sistemas de realizar inferências e gerar respostas contextualizadas.

2.4.1 Definição e Estrutura das Ontologias

Maurício Barcellos, pioneiro no estudo das ontologias no Brasil, define ontologias como “sistemas formais que representam conceitos e suas relações dentro de um domínio, estabelecendo uma estrutura que auxilia na organização e compartilhamento de conhecimento” [Almeida, 2020]. Em sua obra, Barcellos enfatiza que o objetivo principal das ontologias é proporcionar uma linguagem comum e rigorosa, que permita a interoperabilidade semântica entre diferentes sistemas computacionais. Ele destaca que, para alcançar esse objetivo, é fundamental que a estrutura ontológica seja baseada em princípios sólidos, como consistência, extensibilidade e reusabilidade.

Barcellos também introduz a ideia de que ontologias podem atuar como um "hub de conhecimento", conectando diferentes sistemas e viabilizando a integração de dados de forma padronizada [Almeida, 2020]. Esse conceito reforça o papel essencial das ontologias em contextos complexos, onde a diversidade de fontes e formatos de dados exige uma representação uniforme e sem ambiguidades.

A partir dessa base estabelecida, Barry Smith, um dos nomes mais reconhecidos no cenário internacional, expande a definição ao apresentar as ontologias como “esquemas de conhecimento estruturados que formalizam a realidade de um domínio” [Smith and Grenon, 2004]. Para Smith, uma ontologia deve não apenas listar conceitos isolados, mas também mapear as inter-relações que organizam esses conceitos, permitindo que sistemas computacionais realizem inferências sobre o conhecimento representado. Ele argumenta que essa abordagem promove uma compreensão mais profunda e formalizada das entidades e suas relações, sendo especialmente útil para a interoperabilidade em contextos de inteligência artificial.

No cenário contemporâneo, Fernanda Farinelli, em seu trabalho [Farinelli, 2020], propõe a classificação das ontologias em diferentes níveis de abstração, destacando a importância das ontologias de domínio e de alto nível. As ontologias de domínio, segundo Farinelli, oferecem representações específicas para áreas determinadas, como medicina ou direito. Já as ontologias de alto nível, como a *Basic Formal Ontology* (BFO), servem como frameworks genéricos, capazes de sustentar e integrar ontologias mais especializadas. Farinelli reforça que essa hierarquia é crucial para garantir a coerência e a interoperabilidade entre diferentes sistemas que utilizam representações ontológicas.

2.4.2 Abordagens de Ontologias em Diversas Disciplinas

As ontologias, enquanto artefatos de organização do conhecimento, são abordadas de maneiras distintas nas grandes áreas de conhecimento como Filosofia, Ciência da Informação (CI) e Ciência da Computação (CC). Essa diferença reflete as prioridades e perspectivas metodológicas de cada área.

Na Ciência da Informação, o foco está no aprofundamento semântico e na representação precisa do conhecimento. Segundo Barcellos, ontologias, tesauros e taxonomias desempenham papéis cruciais na construção de sistemas informacionais que buscam refletir com rigor as relações conceituais de um domínio [Almeida, 2014]. Essa área valoriza a construção de esquemas que preservem a coerência e a consistência na representação do conhecimento, frequentemente adotando princípios filosóficos e lógicos para estruturar suas propostas.

Por outro lado, na Ciência da Computação, a ênfase recai sobre a aplicação prática das ontologias, muitas vezes sem explorar profundamente as distinções conceituais entre diferentes tipos de artefatos. O objetivo principal é otimizar a eficiência computacional e a integração tecnológica, permitindo que as ontologias sejam implementadas em sistemas de informação complexos. De acordo com Farinelli, essa abordagem pragmática muitas vezes prioriza a viabilidade técnica em detrimento da precisão conceitual, refletindo o foco da área em resultados funcionais [Farinelli, 2020].

Nesse contexto da CC, a ontologia é utilizada para organizar o conhecimento, focando especialmente no raciocínio lógico. Em vez de apenas categorizar objetos ou conceitos, a abordagem enfatiza como as premissas podem ser combinadas para chegar a conclusões válidas, um processo central nas lógicas formais. Dessa forma, as ontologias são vistas como estruturas conceituais que organizam o conhecimento de maneira formal, utilizando um vocabulário lógico para representar conceitos e suas inter-relações [Felipe, 2020].

Maurício Barcellos, em sua obra [Almeida, 2014], sugere que essas perspectivas, apesar de distintas, podem convergir em uma abordagem integrada que aproveite as forças de cada disciplina. O autor destaca que a Ciência da Informação pode contribuir com rigor conceitual, enquanto a Tecnologia da Informação traz eficiência e viabilidade prática, formando um diálogo interdisciplinar enriquecedor.

Além disso, a filosofia desempenha um papel essencial na fundamentação das ontologias. Apesar de não ser o foco deste trabalho, é importante mencionar sua influência na organização e representação do conhecimento. Autores como Barry Smith destacam que os princípios filosóficos, como ontologia formal e realismo ontológico, ajudam a moldar as bases teóricas que sustentam as práticas atuais em CI e CC [Smith and Grenon, 2004].

Essa análise demonstra como as ontologias servem de ponte entre diferentes disciplinas, destacando suas contribuições específicas e suas limitações. Ao unir as perspectivas da Ciência da Informação, Ciência da Computação e Filosofia, torna-se possível construir sistemas mais robustos, tanto do ponto de vista conceitual quanto prático.

2.4.3 Tipos de Ontologias e suas Aplicações

Embora a CC adote as ontologias enquanto artefatos de representação do conhecimento, há diferenças que merecem nossa atenção. A distinção entre ontologias de domínio e ontologias de alto nível é essencial para compreender suas aplicações e limitações.

No entanto, nem todos os artefatos utilizados em sistemas computacionais e de informação possuem as características necessárias para serem considerados ontologias no sentido estrito. Um exemplo é a base semântica SNOMED CT, amplamente utilizada como uma terminologia clínica para padronização de informações na área da saúde. Embora tenha sido anteriormente categorizada como ontologia, hoje a comunidade científica a reconhece como uma terminologia estruturada, dada a adoção de convenções que não refletem os princípios de uma ontologia formal, como apontado em sua definição oficial [SNOMED International, 2024]. Esse caso destaca a importância de diferenciar terminologias, taxonomias, bases semânticas e ontologias para evitar ambiguidades no desenvolvimento de sistemas baseados em conhecimento.

A integração entre ontologias de domínio e ontologias de alto nível continua sendo uma estratégia essencial para garantir a consistência semântica e a interoperabilidade entre sistemas. Na obra [Farinelli, 2020], Farinelli argumenta que essa integração promove maior padronização, ampliando a reutilização do conhecimento e facilitando a

comunicação entre diferentes aplicações computacionais. No contexto da inteligência artificial generativa, essa abordagem é especialmente relevante, pois, ao permitirem a representação robusta de conceitos e a realização de inferências automáticas com precisão, as ontologias fornecem à IA generativa uma base de conhecimento estruturada e qualificada que aprimora sua compreensão e a relevância das respostas.

Portanto, a escolha adequada entre terminologias, taxonomias e ontologias depende diretamente do propósito do sistema em desenvolvimento. Ontologias de domínio fornecem um detalhamento aprofundado de áreas específicas, enquanto ontologias de alto nível estruturam o conhecimento de forma abrangente e universal. Ambas desempenham papéis complementares no avanço da ciência e da tecnologia.

2.4.4 Ontologias e a Linguagem Natural

No contexto do Processamento de Linguagem Natural (PLN), ontologias desempenham um papel crucial na melhoria da precisão semântica de respostas geradas por IA. Farinelli explora essa relação em [Farinelli, 2021], onde ressalta que ontologias oferecem uma estrutura de referência para o significado dos termos, o que possibilita que modelos de IA interpretem corretamente o contexto e as nuances da linguagem humana. Por meio do reconhecimento de entidades e da resolução de ambiguidade semântica, as ontologias fornecem uma base sólida para que a IA trate as consultas dos usuários de maneira mais precisa e contextualizada.

Essa aplicação é especialmente importante na engenharia de *prompt*, pois a utilização de ontologias como fonte de conhecimento para o enriquecimento de *prompts* permite que o sistema de IA acesse e utilize definições, relações e conceitos previamente estruturados para ajustar suas respostas de forma mais alinhada às expectativas do usuário.

Adicionalmente, em Othero and Menuzzi [2005], os autores discutem como representações formais do conhecimento desempenham um papel essencial no PLN, abordando a resolução de ambiguidades e a criação de relações contextuais entre termos. Os autores enfatizam que métodos baseados em análises semânticas e estruturas linguísticas fornecem a base necessária para que sistemas computacionais entendam e processem a linguagem humana de maneira mais eficaz, o que se alinha diretamente ao uso de ontologias para enriquecer *prompts* e melhorar a precisão das respostas geradas

por IA.

2.4.5 Ferramentas e Padrões de Ontologias

Para o desenvolvimento e a implementação de ontologias, diversas ferramentas e padrões têm sido amplamente adotados. Linguagens como o OWL ⁷ são utilizadas para modelar e estruturar ontologias de maneira formal e padronizada, facilitando a interoperabilidade entre sistemas. Segundo [Horridge et al., 2011], o OWL é essencial para garantir que ontologias possam ser compreendidas e utilizadas por diferentes sistemas e plataformas de IA.

Entretanto, outro modelo padrão para intercâmbio de dados é o RDF ⁸, que surge como uma alternativa amplamente utilizada para a representação e leitura de ontologias, especialmente no contexto da web semântica. Diferentemente do OWL, que oferece maior expressividade para modelar relações complexas entre conceitos, o RDF se concentra na descrição de recursos e suas relações em forma de triplas simples (sujeito, predicado, objeto). Segundo Klyne and Carroll [2004], o RDF é ideal para aplicações onde a simplicidade e a interoperabilidade são mais importantes do que a complexidade lógica. Além disso, como destacado em Manola and Miller [2004], o RDF é suportado por uma vasta gama de ferramentas e padrões, permitindo a integração de dados distribuídos em diferentes sistemas, o que o torna especialmente útil em ambientes onde a interoperabilidade é um requisito essencial.

Além disso, o portal Ontobee serve como um repositório de ontologias padronizadas que seguem as diretrizes da OBO Foundry, uma iniciativa que promove a criação de ontologias interoperáveis e de alta qualidade para a ciência da informação [Consortium, 2024]. Essa padronização é crucial para garantir que diferentes sistemas de IA possam acessar e utilizar as mesmas estruturas de conhecimento, promovendo uma integração eficaz entre diferentes áreas de estudo.

⁷ Ontology Web Language: <https://www.w3.org/OWL/>. Acessado em: 05/10/2024.

⁸ Resource Description Framework: <https://www.w3.org/RDF/>. Acessado em: 05/10/2024.

2.4.6 Realismo Ontológico e a *Basic Formal Ontology*

O conceito de realismo ontológico, amplamente discutido por Smith, sustenta que ontologias devem representar entidades que realmente existem no mundo real, evitando abstrações que comprometam a precisão e aplicabilidade dos dados representados [Smith, 2005]. Essa visão é complementada pelas contribuições de Barcellos, que introduziu na academia brasileira a importância de alinhar as ontologias às realidades observáveis nos domínios onde são aplicadas. Segundo o autor, ontologias baseadas em realismo permitem maior interoperabilidade entre sistemas computacionais e mais consistência na interpretação de conceitos complexos, especialmente em aplicações práticas [Almeida, 2014].

Farinelli, seguindo essa linha de pensamento, ampliou o debate ao explorar como o realismo ontológico pode ser aplicado em sistemas computacionais modernos. Em seus trabalhos, Farinelli discute o papel de ontologias de alto nível, como a *Basic Formal Ontology* (BFO), que exemplifica os princípios do realismo ao organizar categorias universais e fundamentais que refletem a realidade observável [Farinelli, 2020].

A *BFO* destaca-se como uma das ontologias de alto nível mais utilizadas, fornecendo uma estrutura robusta e adaptável a diferentes domínios do conhecimento. Essa abordagem orientada ao realismo, combinando as contribuições de Smith, Barcellos e Farinelli, é essencial para garantir que as ontologias sejam aplicáveis em contextos científicos e tecnológicos complexos, onde a precisão e a confiabilidade do conhecimento representado são vitais.

Sob esse prisma, é interessante explorar como essas abordagens podem ser integradas a técnicas de expansão de consultas. Essa metodologia, comumente utilizada para melhorar a precisão e relevância das respostas em sistemas de recuperação de informação, pode ser potencializada por ontologias, fornecendo um contexto mais rico e estruturado para o processo de busca. A seguir, serão discutidos alguns dos princípios e métodos da Expansão de Consultas, além de como ela pode ser aplicada de maneira eficaz em sistemas de inteligências artificiais generativas.

2.5 Expansão de Consultas (*Query Expansion*)

A *Query Expansion* (QE) é uma técnica amplamente utilizada em sistemas de recuperação de informação (*Information Retrieval*) para aprimorar a relevância e a precisão dos resultados obtidos. Essa abordagem consiste em expandir consultas originais, frequentemente curtas ou ambíguas, por meio da inclusão de termos adicionais que refinem ou ampliem o escopo da busca.

O conceito de QE remonta aos trabalhos iniciais de Gerard Salton, um dos pioneiros da área de Recuperação de Informação, que estabeleceu as bases para o uso de técnicas de expansão de consultas em sistemas de busca [Salton and Yu, 1975]. Sua contribuição foi fundamental para a introdução de métodos computacionais que permitem melhorar os resultados das pesquisas, ajustando a consulta inicial de forma a capturar termos relacionados e semanticamente relevantes.

A eficácia da QE está ligada à sua capacidade de alinhar a intenção do usuário com os resultados retornados pelo sistema, reduzindo ambiguidades e aumentando a abrangência sem sacrificar a precisão [Baeza-Yates and Ribeiro-Neto, 2011, Manning et al., 2008].

2.5.1 *Information Retrieval* (IR) e o Papel da Expansão de Consultas

Os sistemas de recuperação de informação (IR) buscam identificar, em grandes bases de dados, os documentos mais relevantes para uma consulta específica. Esses sistemas têm evoluído significativamente desde os anos 1960, acompanhando o aumento exponencial do volume de informações digitais disponíveis. Segundo [Baeza-Yates and Ribeiro-Neto, 2011], a qualidade dos resultados depende, em grande parte, da formulação da consulta inicial. No entanto, a linguagem natural utilizada pelos usuários pode conter ambiguidades ou ser insuficiente para capturar o significado completo do que está sendo buscado. Nesse contexto, a QE desempenha um papel crucial ao complementar consultas iniciais com termos mais específicos, contextualmente relevantes ou semanticamente relacionados.

2.5.2 Modelo Vetorial e o Conceito de Relevância

Introduzido por Salton, o modelo vetorial é um dos principais paradigmas em recuperação de informação. Esse modelo representa documentos e consultas como vetores em um espaço multidimensional, onde cada dimensão corresponde a um termo único [Salton and Yu, 1975]. A relevância de um documento para uma consulta é calculada com base na similaridade entre seus vetores, frequentemente usando o cosseno do ângulo entre eles. A expansão de consultas nesse modelo pode influenciar diretamente a relevância dos resultados, uma vez que novos termos adicionados à consulta podem alterar sua posição no espaço vetorial, aproximando-a de documentos mais pertinentes.

2.5.3 Técnicas de Expansão de Consultas

As técnicas de QE podem ser classificadas em métodos automáticos, manuais ou híbridos. Segundo [Azad and Deepak, 2019], elas incluem:

- **Expansão baseada em tesouros e redes semânticas:** Essa técnica utiliza recursos como WordNet ou SNOMED CT para adicionar termos semanticamente relacionados à consulta. Por exemplo, [Zivaljevic et al., 2020] demonstraram que a utilização de SNOMED CT em resumos clínicos melhorou significativamente a cobertura de termos, ampliando a precisão em contextos médicos.
- **Análise de co-ocorrência de termos:** Baseada na frequência com que os termos aparecem juntos em um conjunto de documentos, essa técnica infere relações contextuais entre palavras para expandir consultas.
- **Feedback de relevância:** Após uma busca inicial, o sistema analisa documentos considerados relevantes e utiliza termos desses documentos para refinar a consulta.
- **Aplicação de terminologias estruturadas:** Aplicar terminologias estruturadas não apenas facilita a inclusão de termos semanticamente relacionados, mas também evita redundâncias, garantindo que resultados já recuperados por outros termos não sejam duplicados. Esse enfoque melhora a eficiência da consulta e preserva a qualidade da recuperação de informação [Almeida and Felipe, 2021].

Essas abordagens destacam a importância de combinar estratégias linguísticas e estatísticas para capturar nuances semânticas e melhorar os resultados de IR.

2.5.4 Técnicas de Substituição de Termos

Dentro do contexto da expansão semântica de consultas, a substituição de termos é uma técnica complementar que busca reformular uma consulta inicial substituindo palavras por sinônimos, hiperônimos ou termos mais específicos. Esse processo é particularmente útil em cenários onde os termos originais são ambíguos ou têm múltiplos significados contextuais. Segundo [Almeida and Felipe, 2021], no contexto de terminologias biomédicas, a substituição cuidadosa de termos pode reduzir a carga cognitiva do usuário ao formular consultas, aumentando a precisão sem aumentar a complexidade do sistema de recuperação. Isso pois a capacidade de representar o mesmo conceito em diferentes formas sintáticas é crucial para resolver ambiguidades e expandir consultas de forma significativa, conectando sinônimos e variações linguísticas sem perder a precisão.

A aplicação de substituição de termos também se beneficia de avanços em Processamento de Linguagem Natural e bases semânticas como SNOMED CT. De acordo com [Zivaljevic et al., 2020], a substituição automatizada de termos em resumos clínicos resultou em melhores índices de recuperação ao evitar problemas de sinonímia e polissemia.

2.5.5 Integração com Inteligências Artificiais Generativas

No contexto das IAs generativas, as técnicas de QE e substituição de termos apresentam um potencial significativo. Os aportes teóricos apontam que há um grande potencial de melhoria dos *prompts* fornecidos aos modelos, oferecendo contexto adicional e alinhando melhor as consultas com as capacidades de processamento dessas ferramentas avançadas.

A capacidade de mapeamento semântico descrita no trabalho [Almeida and Felipe, 2021] é particularmente valiosa, pois permite que os *prompts* incorporados a essas ferramentas reflitam uma compreensão mais robusta do contexto e da intenção do usuário. Isso não apenas melhora os resultados, mas também promove uma experiência mais consistente e confiável.

Assim, QE se consolida como uma abordagem essencial não apenas em IR, mas também em sistemas de interação homem-máquina e inteligência artificial.

3 Metodologia

Para atender aos objetivos desta pesquisa, foi essencial estabelecer um planejamento prévio que definisse as etapas do desenvolvimento prático do projeto. Esse planejamento teve papel crucial ao estruturar uma abordagem que orientasse a criação das entregas, assegurando que os resultados esperados fossem alcançados de forma eficiente e alinhada ao escopo estabelecido, conforme as diretrizes dos processos de "*Plan Scope Management*", "*Plan Schedule Management*" e "*Plan Risk Management*", descritos no *PMBOK Guide* [Project Management Institute, 2021].


Inicialmente, definiu-se o escopo do projeto, incluindo o levantamento de prazos e recursos necessários. Também foram delineadas as funcionalidades a serem implementadas, bem como selecionadas as ferramentas e tecnologias capazes de atender a esses requisitos. Os objetivos relacionados ao software serão detalhados e analisados nesta seção.

3.1 Arquitetura Geral do Sistema

Esta seção apresenta a arquitetura geral do sistema desenvolvido, que é composto por três módulos principais: *front-end*, *back-end* e a Ontologia como base de conhecimento.

A Figura 1 apresenta um diagrama que sintetiza os componentes dessa arquitetura, destacando as interconexões entre o *front-end*, o *back-end* e a ontologia. Este diagrama ilustra claramente o fluxo de dados desde a entrada do usuário até o processamento e a expansão do *prompt*, detalhando como cada módulo interage para a execução das operações.

Figura 1 – Diagrama representativo da interação entre os sistemas.



Fonte: Autores.

A seguir, detalham-se os principais componentes e etapas do fluxo:

1. **Interface com campo de texto aberto para o usuário digitar o *prompt* inicial:** Essa interface é o ponto de entrada do sistema. O usuário fornece um *prompt* em linguagem natural, acompanhado da seleção de um "nível de precisão"¹, que pode ser alterado. A simplicidade dessa interface visa facilitar o uso e garantir acessibilidade.
2. **API que recebe o *input* (*string*) e o nível de precisão selecionado:** O texto digitado é enviado para uma rota da API, responsável por atuar como camada de comunicação inicial do sistema. Essa API transforma o *input* em um formato apropriado para o processamento subsequente.
3. **Processamento em PLN:** Os dados recebidos são enviados a um módulo de Processamento de Linguagem Natural (PLN), responsável por realizar análises preliminares utilizando a biblioteca *spaCy*², como a extração de tokens, segmentação, extração de entidades e identificação de estrutura semântica.
4. **Identificação de termos-chave para consulta à ontologia:** O módulo de PLN extrai termos relevantes do *prompt* inicial, identificando palavras ou expressões-

¹ A configuração dos níveis de precisão e suas implicações serão vistas no item 3.2.2.1

² <https://spacy.io>. Acessado em: 25/03/2025.

chave que serão utilizadas na consulta à ontologia. Essa etapa é essencial para alinhar a intenção do usuário ao conhecimento formalizado.

5. **Sistema de *parse* da ontologia:** A ontologia, representada no formato *Ontology Web Language* (OWL)³, contém descrições semânticas e estruturadas que organizam o conhecimento sobre emoções humanas, adotando uma abordagem interdisciplinar. A MFOEM é consultada por meio de um algoritmo escrito em Python, usando a biblioteca *OwlReady2*, que a partir dos termos extraídos pelo módulo de PLN, encontra termos e/ou expressões equivalentes, essas que permitem a expansão do *prompt*.
6. **Interpretação e avaliação dos dados:** A resposta da ontologia, composta por conceitos e relações relevantes, é avaliada pelo sistema e categorizada para que a próxima etapa de processamento utilize as relações de maior relevância com o *prompt* original.
7. **Expansão do *prompt* com base nas equivalências relevantes:** Com os dados estruturados, este módulo realiza a expansão do *prompt* original utilizando os conceitos encontrados na ontologia, preservando o contexto e a intenção do usuário. Este processo adiciona novos termos com base em um sistema de avaliação de similaridade e por meio de uma construção sintática baseada no nível de relação encontrada na ontologia.
8. **Interface de exibição do *prompt* enriquecido:** O *prompt* enriquecido é apresentado ao usuário por meio de uma interface minimalista. A interface também disponibiliza uma opção de “*Show Advanced Details*”, permitindo o acesso aos dados semânticos utilizados no processo.

Dessa forma, esta metodologia procurará apresentar uma visão sistemática e coerente do processo de desenvolvimento do protótipo, refletindo as decisões técnicas tomadas ao longo de sua implementação. A seguir, detalham-se os passos realizados para a construção de um protótipo capaz de validar os objetivos propostos neste trabalho.

³ <https://www.w3.org/OWL/>. Acessado em: 22/03/2025.

3.2 Desenvolvimento do Protótipo

O desenvolvimento do protótipo foi dividido em etapas, cada uma responsável por uma camada do sistema: *back-end*, ontologia e *front-end*. Cada parte foi construída utilizando tecnologias específicas, integradas para proporcionar uma experiência de usuário fluida e funcional. Esta seção descreve os aspectos técnicos e conceituais envolvidos na construção do sistema, bem como as dificuldades enfrentadas ao longo do processo.

3.2.1 Internacionalização do Protótipo

Para ampliar a discussão a respeito deste tema e aderir às práticas consolidadas na área de computação, a interface do protótipo foi desenvolvida inteiramente no idioma inglês[Science, 2023][Gordin, 2018b]. No contexto da computação, o inglês consolidou-se como a *lingua franca*, sendo empregado em conferências, periódicos e vocabulário técnico de linguagens de programação[ScienceDirect, 2025].

Adicionalmente, a ontologia escolhida para implementar a solução foi a MFOEM (*Emotion Ontology*)⁴, base semântica central neste trabalho, que se encontra inteiramente estruturada em inglês, o que torna natural a escolha desse idioma para as consultas.

Acrescenta-se a este cenário, que eventos como o Seminário Brasileiro de Pesquisa em Ontologias (ONTOBRAS) recomendam submissões preferencialmente em inglês, de modo a ampliar o alcance e a visibilidade das publicações[UFRGS, 2025][Instituto de Informática, 2024]. De igual forma, conferências e periódicos da *Association for Computing Machinery* (ACM) estabelecem o inglês como idioma oficial de submissão, maximizando o impacto científico dos trabalhos[for Computing Machinery, 2025].

Por fim, estudos sobre o papel do inglês como *Academic Lingua Franca* apontam que sua hegemonia facilita a disseminação global do conhecimento, embora imponha desafios a pesquisadores não-nativos[Alhasnawi et al., 2023][Gordin, 2018a].

3.2.2 Back-end

A construção do algoritmo prototipal teve início pelo desenvolvimento do *back-end*, que representa o núcleo funcional deste projeto. É nessa camada que ocorre a

⁴ <https://ontobee.org/ontology/mfoem>. Acessado em: 24/03/2025.

transformação da entrada fornecida pelo usuário — um *prompt* em linguagem natural — em uma saída enriquecida semanticamente, por meio de técnicas de Processamento de Linguagem Natural (PLN), *Query Expansion* e consulta a ontologias especializadas.

Para a implementação dessa camada, optou-se pela linguagem de programação Python. Essa escolha se justifica por diversos fatores relevantes ao escopo da pesquisa. Em primeiro lugar, Python apresenta ampla compatibilidade com bibliotecas e frameworks voltados a PLN e inteligência artificial, tais como *spaCy*, *transformers* e *sentence-transformers*⁵, amplamente utilizados neste trabalho e detalhadas mais à frente. Em segundo lugar, sua sintaxe de alto nível e a vasta comunidade ativa facilitam o desenvolvimento rápido e a resolução de problemas, aspectos fundamentais em projetos acadêmicos com prazos curtos e bem definidos.

Além disso, Python oferece suporte à manipulação de dados textuais e integração com ontologias no formato OWL, por meio de bibliotecas a exemplo da *Owlready2*⁶. Essa característica foi determinante para possibilitar o processamento entre os dados extraídos do *prompt* e os conceitos semânticos definidos na ontologia MFOEM, elemento central na proposta de enriquecimento de *prompts*.

Durante o desenvolvimento do *back-end*, foram utilizadas diversas bibliotecas que oferecem suporte ao processamento de linguagem natural, consulta a ontologias e estruturação de interfaces programáticas. A seguir, apresenta-se uma descrição das bibliotecas utilizadas, suas respectivas funções, alternativas consideradas e critérios de escolha:

- **FastAPI:** *Framework* moderno e de alto desempenho para construção de APIs com Python.

Alternativas consideradas: *Flask* e *Django REST Framework* foram avaliados. O *Flask* é leve e flexível, mas carece de suporte nativo a tipagem e documentação automática; já o *Django REST Framework* oferece recursos avançados de autenticação e administração, porém impõe maior complexidade e sobrecarga de estrutura.

⁵ <https://www.sbert.net>. Acessado em: 25/03/2025.

⁶ <https://pypi.org/project/Owlready2/>. Acessado em: 25/03/2025.

Critério de escolha: optou-se pelo *FastAPI* devido à tipagem estática oferecida pelo *Pydantic*, à geração automática de documentação *OpenAPI/Swagger* e ao desempenho superior em *benchmarks* ASGI, o que agilizou o desenvolvimento e garantiu respostas rápidas sem sacrificar a manutenibilidade.

- ***Uvicorn*:** Servidor ASGI leve e assíncrono, frequentemente utilizado com o *FastAPI*.

Alternativas consideradas: *Gunicorn* (WSGI) e *Hypercorn* (ASGI). *Gunicorn* é maduro e estável, mas não suporta nativamente concorrência assíncrona; *Hypercorn* oferece características similares ao *Uvicorn*, porém apresenta comunidade menor e menos exemplos de configuração.

Critério de escolha: *Uvicorn* foi escolhido por sua integração *out-of-the-box* com *FastAPI*, baixo consumo de memória, facilidade de configuração e comprovada performance em cenários assíncronos, atendendo bem aos requisitos de escalabilidade.

- ***Owlready2*:** Biblioteca para manipulação de ontologias no formato OWL.

Alternativas consideradas: *RDFLib* para grafos RDF e *OWL API* (Java). *RDFLib* é versátil para qualquer grafo RDF, porém carece de suporte avançado a raciocínio OWL; *OWL API* é robusta, mas exigiria interoperabilidade Java-Python (via *JPyype*), aumentando a complexidade.

Critério de escolha: *Owlready2* fornece carregamento direto de arquivos OWL, raciocínio automático (*Hermit/Towl*), e API Python nativa, simplificando consultas hierárquicas e classificação de classes sem configurações adicionais.

- ***Transformers*:** Biblioteca da *Hugging Face* que fornece modelos pré-treinados de linguagem (por exemplo, BERT, GPT).

Alternativas consideradas: treinamento próprio de modelos *Word2Vec/GloVe* via *Gensim* ou uso de *spaCy pipelines* embutidos. *Word2Vec/GloVe* demandaria grande

corpus e tempo de treinamento; *spaCy* oferece vetores estáticos, mas sem o poder contextual dos transformers.

Critério de escolha: os *transformers* permitem obter representações contextualizadas de alta qualidade, sem necessidade de treinar do zero, acelerando o desenvolvimento e melhorando a precisão semântica.

- **Sentence-Transformers:** Extensão da *Hugging Face* voltada à obtenção de *embeddings* de sentenças.

Alternativas consideradas: *Universal Sentence Encoder (TensorFlow)* ou métodos baseados em média de tokens (*BERT-average*). *USE* é robusto, mas requer *TensorFlow* e tem maior custo de inferência; técnicas de média BERT podem diluir o contexto.

Critério de escolha: *Sentence-Transformers* foi escolhido com base em um modelo particular - o *all-MiniLM-L6-v2* - que equilibra leveza e precisão, oferecendo *embeddings* de sentença otimizados para similaridade semântica, com menor latência.

- **spaCy:** Ferramenta de PLN para tokenização, lematização, NER e POS *tagging*.

Alternativas consideradas: *NLTK*, *Stanza* e *Flair*. *NLTK* é educacional e fragmentado; *Stanza* oferece modelos de *Stanford* de alta precisão, porém com maiores requisitos de memória; *Flair* fornece *embeddings* contextuais, mas não inclui *pipelines* tão integrados.

Critério de escolha: *spaCy* foi escolhido pela combinação de velocidade, API unificada e facilidade de customização de *pipelines*, além de vasta documentação e compatibilidade com extensões de terceiros.

- **MkDocs:** Ferramenta para geração de documentação estática a partir de *Markdown*.

Alternativas consideradas: *Sphinx* e *Jekyll*. *Sphinx* é poderoso para documentação

técnica, mas exige *reStructuredText* e curva de aprendizado maior; Jekyll é focado em sites genéricos, sem recursos específicos para *docs* de código.


Critério de escolha: *MkDocs* permite escrever toda a documentação em *Markdown*, com configuração simples em YAML, e integra-se bem a repositórios *GitHub Pages*, acelerando a entrega da documentação.

- ***MkDocs-Material*:** Tema baseado em *Material Design* para *MkDocs*.

Alternativas consideradas: temas nativos do *MkDocs* e outros temas comunitários. Os temas padrões são básicos, sem componentes modernos; alternativas personalizadas requerem desenvolvimento CSS extra.

Critério de escolha: *MkDocs-Material* fornece componentes responsivos, esquema de cores configurável e *plugins* prontos (busca, navegação lateral), garantindo documentação clara e visualmente atraente sem esforço de estilo adicional.

A Figura 2 ilustra o fluxo de processamento do *back-end*, responsável pela orquestração das etapas que transformam um *prompt* inicial em um *prompt* enriquecido. Cada serviço aplica o princípio SOLID[Martin, 2002], isolando responsabilidades para facilitar a manutenção.

Figura 2 – Diagrama de funcionamento do *back-end*.

Fonte: Autores.

- **Prompt Controller** (`prompt_controller.py`): componente responsável por intermediar a comunicação com o cliente, expondo o *endpoint* `/enrich_prompt`, que utiliza o verbo POST. Sua principal função é receber e validar o *prompt* inicial e o nível de precisão informados pelo usuário. Em seguida, aciona o *Prompt Service* para realizar o enriquecimento do *prompt* e, por fim, formata a resposta HTTP de acordo com os princípios do padrão REST, abstraindo os detalhes de implementação dos serviços internos [Fielding, 2000].
- **Prompt Service** (`prompt_service.py`): orquestra a sequência de chamadas entre todos os serviços, garantindo a integridade do fluxo [Martin, 2002].
- **Text Processing Service** (`text_processing_service.py`): extrai e lematiza termos-chave do *prompt* original, sustentando a consulta semântica [Honnibal and Montani, 2020].
- **Ontology Service** (`ontology_service.py`): pesquisa classes e relações na ontologia MFOEM, filtrando resultados por limiar de similaridade [Lamy, 2017].
- **Similarity Service** (`similarity_service.py`): avalia correspondência semântica entre termos e rótulos ontológicos via *embeddings* [Reimers and Gurevych, 2019].

- **New Content Service** (`new_content_service.py`): gera sentenças adicionais que enriquecem o *prompt*, articulando termos centrais e correlatos encontrados na ontologia [Wolf et al., 2020].

3.2.2.1 Funcionamento do Fluxo

Detalhando o fluxo mostrado na Figura 2, o funcionamento segue as seguintes fases:

1. **Recebimento do *prompt***: o *endpoint* POST `/enrich_prompt`, implementado no *Prompt Controller*, recebe o texto e aciona o *Prompt Service*.
2. **Pré-processamento**: o *Text Processing Service* realiza tokenização, lematização e extração de entidades nomeadas usando *spaCy*.
3. **Consulta à ontologia**: o *Ontology Service* pesquisa a ontologia MFOEM via *Owlready2*, extraíndo rótulos de classes pais, filhos e correlatas.
4. **Cálculo de similaridade**: o *Similarity Service* computa similaridade semântica por cosseno de *embeddings* gerados com *Sentence-Transformers*, utilizando também o *spaCy*.
5. **Geração de novos conteúdos**: o *New Content Service* elabora frases dinâmicas para expandir o *prompt*, mantendo coerência textual.
6. **Filtragem de relevância**: para que os novos conteúdos sejam válidos, o *Similarity Service* filtra a relevância dos termos ancestrais, pais, irmãos e filhos utilizando o *threshold*.
7. **Retorno ao usuário**: *New Content Service* envia o novo conteúdo para o *Prompt Service*, esse que agrega os resultados e devolve o *prompt* expandido ao *Prompt Controller*, que responde à requisição HTTP.

3.2.2.2 Geração de Novos Conteúdos

Para de fato aplicar as técnicas de *query expansion* alinhadas com as equivalências relevantes encontradas na ontologia, foi desenvolvido um método de geração dinâmica de

frases. Este método tem como objetivo enriquecer o *prompt* original adicionando novas informações contextuais e semânticas, extraídas diretamente da ontologia.

Orquestrado pelo *New Content Service*, o processo funciona da seguinte forma:

1. **Extração e Filtragem de Termos Ontológicos:** A partir dos *termos-chave* identificados no *prompt* original e dos conceitos correspondentes na ontologia, o sistema recupera relações hierárquicas e correlatas, como pais, filhos, irmãos e ancestrais. Esses termos são então filtrados com base no *threshold* de similaridade definido pelo usuário, garantindo a relevância semântica.
2. **Seleção de Modelos de Frase:** Para cada *termo-chave* e sua relação ontológica relevante, o sistema seleciona aleatoriamente um *template* de frase a partir de um conjunto pré-definido (PHRASE_TEMPLATES). Esses *templates* são estruturados para expressar diferentes tipos de relações (ex: "*influenced by*", "*affects*", "*related to*", "*rooted in*"), como mostrado na Figura 3.
3. **Geração de Sentenças Dinâmicas:** Os *templates* de frase são preenchidos com o termo original ('A') e o termo ontológico relacionado('B'), criando sentenças em linguagem natural. Por exemplo, se "tristeza" é 'A' e "grief" (luto) é 'B', uma frase como "*Exploring the link between sadness and grief, what insights emerge?*" pode ser gerada.
4. **Composição do Parágrafo Enriquecido:** As sentenças geradas são concatenadas para formar um parágrafo coeso, utilizando conectores variados (ex: "*Additionally*", "*Moreover*", "*Interestingly*") para garantir fluidez textual. Limites de geração (por exemplo, máximo de 3 frases por termo e um total de 15 frases por *prompt*) são aplicados para evitar a proliferação excessiva de conteúdo.
5. **Ajuste de Pontuação:** É realizada uma verificação final para garantir que o *prompt* enriquecido termine com a pontuação adequada.

Figura 3 – Conjunto de frases genéricas criado para adicionar novos conteúdos ao *prompt* original mantendo relevância com os termos encontrados na ontologia.

```

PHRASE_TEMPLATES = {
  "influenced by": [
    "{A} is influenced by {B}. How might this affect its role?",
    "What role does {B} play in shaping {A}?",
    "{A} may be shaped by {B}. Could this influence its relationship with other concepts?"
  ],
  "affects": [
    "{A} may affect {B}. What might be the consequences?",
    "Could {A}'s influence on {B} reveal deeper insights?",
    "How does {A} impact {B} in meaningful ways?"
  ],
  "related to": [
    "{A} seems closely related to {B}. Could this be significant?",
    "Exploring the link between {A} and {B}, what insights emerge?",
    "The relationship between {A} and {B} might offer new perspectives."
  ],
  "rooted in": [
    "{A} appears to be rooted in {B}. What foundational role does this play?",
    "Is {A}'s origin tied to {B}? How might this matter?",
    "{B} might underlie {A}. What broader implications does this have?"
  ],
  "default": [
    "The term {A} has a relationship with {B}. How might this be important?",
    "What could the connection between {A} and {B} suggest?",
    "{A} and {B} share a link—what does this reveal?"
  ]
}

```

Fonte: Autores.

O resultado é um *prompt* expandido que preserva a intenção original do usuário, ao mesmo tempo em que incorpora informações mais detalhadas e contextualmente relevantes, qualificando a entrada para a IA generativa.

3.2.2.3 Lógica de *Thresholds* de Similaridade

Para controlar o grau de exigência na filtragem de correspondências ontológicas, estabeleceu-se um mapeamento entre cinco níveis de precisão (*very_low* a *very_high*) e vetores de *thresholds* de similaridade semântica, variando de 0,05 a 0,99. Cada *threshold* define um limiar mínimo de similaridade de cosseno para que um termo extraído seja considerado relevante. O algoritmo procede iterativamente, testando cada valor de *threshold* em ordem decrescente de permissividade — do mais brando ao mais rigoroso — até

encontrar o primeiro ponto em que o *prompt* seja efetivamente enriquecido. Caso nenhum limiar gere enriquecimento, retorna-se o *prompt* original com indicação de não enriquecimento. Essa abordagem permite balancear sensibilidade e especificidade, adaptando-se às necessidades do usuário e reduzindo o risco de gerar conteúdo irrelevante.

3.2.2.4 Rota auxiliar para cálculo de similaridade semântica

Para facilitar a avaliação qualitativa dos resultados, foi implementado um *endpoint* na API capaz de calcular a similaridade semântica entre duas sequências de texto. A rota `/calculate_similarity` recebe dois valores do tipo `string` e retorna um número entre 0 e 1, representando o grau de similaridade semântica entre os textos.

Figura 4 – Trecho de código que configura a rota `/calculate_similarity` no *Prompt Controller*.

```
@router.post("/calculate_similarity")
def calculate_similarity_controller(request: SimilarityRequest):
    similarity_score = compute_similarity(request.prompt, request.gpt_response)

    return {
        "similarity": round(float(similarity_score), 2)
    }
```

Fonte: Autores.

A função `compute_similarity`, responsável pelo cálculo, foi reutilizada do módulo *Similarity Service*, já presente no algoritmo principal de expansão de *prompts*.

3.2.2.5 Documentação Técnica do *Back-end*


Para facilitar a navegação e o entendimento completo da API, toda a especificação dos *endpoints*, exemplos de *payloads* e detalhes de configuração encontram-se disponíveis online em um portal dedicado⁷. Essa documentação foi gerada com *MkDocs* e atualizada automaticamente a partir dos comentários em código, garantindo consistência entre a implementação e o material de apoio.

⁷ <https://pradopha.github.io/prompt-enricher-backend/>

3.2.3 Ontologia utilizada: MFOEM (*Emotion Ontology*)

Nesta aplicação, adotou-se a ontologia MFOEM (*Emotion Ontology*), uma representação formal de fenômenos afetivos — como emoções, humores, avaliações e sentimentos subjetivos — desenvolvida colaborativamente pelo Swiss Centre for Affective Sciences e pela University at Buffalo [Hastings et al., 2025]. A MFOEM segue os princípios da OBO Foundry e estende a *Mental Functioning Ontology* (MF) e a ontologia de alto nível *Basic Formal Ontology* (BFO), garantindo interoperabilidade semântica e rigor na definição de classes e relações [Foundry, 2024].

Figura 5 – Trecho da ontologia em visualização *OntoGraf*.



Fonte: Extraído do software Protégé⁸ (2025).

Por se tratar de um recurso já estruturado em *OWL*, a ontologia foi integrada ao *back-end* por meio da biblioteca *Owlready2*, que permite carregar o arquivo *MFOEM.owl* e acessar programaticamente suas classes. É importante ressaltar que a ontologia foi

carregada diretamente do diretório do projeto, ao invés de ser consultada em tempo real via web. Essa decisão de projeto foi motivada por duas razões principais: primeiramente, uma limitação inerente à biblioteca *Owlready2*, que opera lendo diretamente arquivos *.owl* armazenados localmente; e, em segundo lugar, para otimizar o desempenho do sistema, evitando o uso excessivo e desnecessário de processamento que ocorreria ao consultar a versão mais recente da ontologia online a cada vez que o projeto fosse acionado. O serviço de ontologia (*ontology_service.py*) percorre cada classe disponível em *onto.classes()*, compara os rótulos (*entity.label*) com os termos extraídos do *prompt* e, quando a similaridade semântica é satisfatória, recupera hierarquias de relações — pais (*is_a*), filhos (*subclasses()*), irmãos e ancestrais — por meio de funções utilitárias como *get_entity_parents* e *get_entity_children*.

Essa configuração possibilita enriquecer o *prompt* com conceitos correlatos obtidos dinamicamente da ontologia, promovendo uma expansão de consulta com base em conhecimento formalizado e atualizável, sem a necessidade de manutenção manual de vocabulários.

Durante o processo de seleção, também foram avaliadas outras ontologias da OBO Foundry, como:

- **Cardiovascular Disease Ontology (CVDO)**: voltada para a representação de doenças cardiovasculares, baseada no OGMS⁹ e estruturada de forma a promover a interoperabilidade entre dados clínicos¹⁰.
- **Compositional Dietary Nutrition Ontology (CDNO)**: fornece vocabulários organizados para descrever propriedades nutricionais de ingredientes alimentares e dietas¹¹.
- **Food Ontology (FoodOn)**: abrange uma ampla gama de termos alimentares, desde ingredientes crus até produtos processados, com ênfase em segurança alimentar e rastreabilidade¹².

⁹ <https://obofoundry.org/ontology/ogms.html>. Acessado em: 04/09/2024.

¹⁰ <https://obofoundry.org/ontology/cvdo.html>. Acessado em: 04/09/2024.

¹¹ <https://obofoundry.org/ontology/cdno.html>. Acessado em: 04/09/2024.

¹² <https://obofoundry.org/ontology/foodon.html>. Acessado em: 04/09/2024.

- **Human Disease Ontology (DOID)**: fornece uma classificação abrangente de doenças humanas com base em etiologia e outros critérios biomédicos¹³.

Apesar da riqueza estrutural das ontologias avaliadas, a MFOEM mostrou-se a alternativa mais viável devido à sua capacidade de:

- Representar relações conceituais de forma intuitiva, evitando termos excessivamente técnicos que dificultariam a interpretação automática pelos módulos de PLN;
- Abranger termos e relações semanticamente alinhados com o vocabulário cotidiano utilizado em *prompts*, facilitando a expansão contextual;
- Permitir integração direta com o *pipeline* de processamento, graças à sua estrutura modular e compatibilidade com o formato padrão (OWL) utilizado neste trabalho.

Sua adoção não apenas otimiza a fase de expansão de *queries*, mas também assegura que os *prompts* expandidos preservem a intenção original do usuário enquanto incorporam precisão semântica.

3.2.4 Front-end

A interface do usuário foi desenvolvida em *React* utilizando o framework *Next.js* [Facebook and Meta Platforms, 2025]¹⁴ [Vercel, 2025b]¹⁵. Essa escolha se apoia na abordagem de *server-side rendering* e geração estática de páginas oferecida pelo *Next.js*, bem como na vasta comunidade e ecossistema de componentes do React.

O arquivo principal, `src/pages/index.tsx`, orquestra a composição da página por meio dos componentes `Layout`, `Header` e `OBPX`. O componente `Layout` aplica estilos globais e estrutura de contêiner responsivo, enquanto o `Header` incorpora a logo da aplicação, título e ícones sociais fornecidos pela biblioteca *react-icons*¹⁶ [Icons, 2025].

¹³ <https://obofoundry.org/ontology/doid.html>. Acessado em: 04/09/2024.

¹⁴ <https://reactjs.org>. Acessado em: 04/04/2025.

¹⁵ <https://nextjs.org>. Acessado em: 04/04/2025.

¹⁶ <https://react-icons.github.io/react-icons>. Acessado em: 04/04/2025.

Figura 6 – Tela inicial do protótipo, com o campo de entrada de prompt e o seletor de precisão.



Fonte: Autores.

O componente OBPX implementa a lógica de estado (`useState`) para armazenar o *prompt*, índice de precisão, estado de carregamento e resultados. Ao acionar o botão “Expand”, é feita uma requisição `fetch` ao *endpoint* `/enrich_prompt` do *back-end*, retornando o objeto `EnrichedPromptResult`. Caso o enriquecimento seja bem-sucedido, o *prompt* expandido é exibido; caso contrário, uma mensagem apropriada é mostrada.

Para melhorar a usabilidade, implementou-se:

- Botão de cópia para área de transferência, com feedback de confirmação do usuário.
- *Toggle* para visualização de “Advanced Details”, apresentando *thresholds*, termos-chave e correspondências ontológicas em formato legível.

- Seletor de precisão (`<input type="range">`) que mapeia níveis descritivos (“*Very low*” a “*Very high*”) aos valores esperados pelo *back-end*.

A estilização foi realizada com *styled-components*, mantendo consistência visual e facilitando a manutenção. A utilização do *Next.js* permite ainda o carregamento otimizado de imagens por meio do componente `next/image` [Vercel, 2025a]¹⁷, contribuindo para performance e responsividade.

3.2.5 Metodologia de Validação da Solução Proposta

Para avaliar de forma objetiva o desempenho do protótipo de enriquecimento de *prompts*, foi desenvolvido um protocolo de avaliações automatizado, com o objetivo de mensurar a diferença semântica entre respostas geradas por uma IA a partir de *prompts* originais e *prompts* expandidos. A estratégia adotada evita a interferência direta de avaliadores humanos e se baseia na análise quantitativa de similaridade semântica.

3.2.5.1 Preparação dos Dados

Selecionou-se um conjunto de **29** *prompts* originais, todos relacionados a emoções humanas como tristeza, alegria, ansiedade, gratidão e frustração. Esses *prompts* originais foram elaborados com diferentes graus de complexidade linguística, visando testar o comportamento do sistema em situações diversas. Um exemplo de *prompt* em linguagem natural sem enriquecimento, foi:

"How can someone cope with sadness after a significant loss?"

Cada *prompt original* foi submetido ao sistema desenvolvido, gerando uma versão enriquecida a partir de consultas ontológicas e técnicas de Processamento de Linguagem Natural (PLN). Ambas as versões — original e expandida — foram armazenadas para posterior envio ao modelo de linguagem.

¹⁷ <https://nextjs.org/docs/api-reference/next/image>. Acessado em: 04/04/2025.


3.2.5.2 Ambientes de Validação Isolados

Todos os testes deste experimento foram realizados exclusivamente com o modelo ChatGPT, disponibilizado pela OpenAI. Para garantir imparcialidade e evitar contaminações por contexto ou histórico de conversas, foram criadas duas sessões independentes no navegador. Essa separação visou impedir o rastreamento de perfil e eliminar qualquer influência por contexto não controlado durante as respostas.

Cada sessão foi vinculada a um endereço de e-mail distinto:

- obpxrawprompts@gmail.com: dedicada aos testes com os *prompts* originais;
- obpxexpandedprompts@gmail.com: dedicada aos testes com os *prompts* expandidos.

Figura 7 – Ambientes de teste configurados no Gmail para isolar o histórico de *prompts*.



Fonte: Extraído da seção de *login* do Google (2025).

Além disso, em ambas as contas, a funcionalidade de “Memória” do ChatGPT foi desativada, assegurando que cada requisição fosse processada de forma independente, sem considerar interações anteriores.

Figura 8 – Configuração do ChatGPT com “Memória” desativada, garantindo independência entre requisições.




Fonte: Extraído da seção de configuração do ChatGPT (2025).

3.2.5.3 Execução dos Testes

O fluxo de execução dos testes seguiu as etapas descritas na Figura 9:

Figura 9 – Fluxograma seguido para execução dos testes.



Fonte: Autores.

Todas as respostas foram documentadas em uma planilha eletrônica do Google Sheets¹⁸, organizada por linha, com colunas correspondentes a: *prompt*, resposta gerada e valor de similaridade.

Para o envio ao *endpoint* (Seção 3.2.2.4), utilizou-se a ferramenta **Insomnia**¹⁹, um cliente HTTP que permite ao usuário construir, testar e enviar requisições a APIs de forma visual e interativa. Ferramentas desse tipo são amplamente utilizadas no desenvolvimento de sistemas para simular chamadas a serviços *back-end*, sem a necessidade de uma interface gráfica completa.

¹⁸ Disponível no Apêndice A.

¹⁹ <https://docs.insomnia.rest/>. Acessado em: 13/01/2025.

No contexto desta pesquisa, o uso do Insomnia proporcionou um ambiente controlado e padronizado para o envio das requisições, permitindo que os testes fossem facilmente repetidos com os mesmos parâmetros e *payloads*, o que garante a reprodutibilidade dos experimentos realizados.

3.2.5.4 Reprodutibilidade e Organização dos Resultados

Todos os dados de entrada e saída foram organizados na mesma planilha eletrônica do Google Sheets utilizada anteriormente²⁰, disponibilizada como material suplementar deste trabalho. Essa documentação inclui:

- *Prompts* originais submetidos ao sistema
- Versões enriquecidas geradas pelo protótipo
- Respostas do ChatGPT para ambos os cenários
- Valores de similaridade semântica calculados

Esse protocolo de testes foi desenvolvido para permitir a replicação do experimento, promovendo transparência e reprodutibilidade dos resultados. A planilha completa, disponível digitalmente, permite:

- Verificação independente dos cálculos
- Análise secundária dos dados
- Adaptação do método para novos testes


²⁰ Ver Apêndice A.

4 Resultados

Nesta seção, apresentam-se os principais resultados obtidos ao longo do desenvolvimento da pesquisa e da implementação do artefato proposto. Serão descritos os testes realizados com o sistema, a metodologia aplicada para mensuração da eficácia dos *prompts* enriquecidos e, por fim, uma análise crítica dos dados coletados. O objetivo é verificar se a abordagem baseada em ontologias e linguagem natural contribui, de fato, para o aprimoramento da interação com modelos de linguagem generativos, conforme delineado nos objetivos deste trabalho.


4.1 *Back-end*

O desenvolvimento da camada de *back-end* em Python, uma escolha estratégica devido à sua robustez, vasta gama de bibliotecas para processamento de linguagem natural e compatibilidade com ferramentas de gestão de ontologias, resultou em uma arquitetura intrinsecamente modular. Essa abordagem modular foi crucial para garantir a escalabilidade, manutenibilidade e flexibilidade do sistema, permitindo que cada componente funcione de forma independente e otimizada. O *back-end* é, de fato, o núcleo de inteligência do sistema, responsável por orquestrar o processamento principal. Suas funcionalidades abrangem a complexa expansão semântica de *prompts*, que enriquece as entradas do usuário com base em conhecimento formalizado, a eficiente consulta à ontologia para recuperação de informações relevantes, e o cálculo preciso de similaridade semântica, essencial para identificar relações e equivalências entre conceitos. A Figura 10 apresenta um diagrama esquemático que detalha visualmente os principais fluxos de dados e os componentes essenciais que compõem essa estrutura sofisticada.

Figura 10 – Diagrama representativo dos módulos que compõem o *back-end*.

Fonte: Autores.

Além do fluxo lógico de execução, a organização interna dos arquivos e diretórios foi planejada para garantir legibilidade, reutilização de código e facilidade de manutenção. A estrutura completa do repositório pode ser visualizada na Figura 11, que mostra a disposição dos módulos por responsabilidade.


Figura 11 – Estrutura de diretórios do repositório *back-end*.

Fonte: Extraído da seção de exibição de arquivos do Visual Studio Code (2025).

O repositório em Python para o *back-end* se encontra no Apêndice B.

4.1.1 Documentação com *MKDocs*

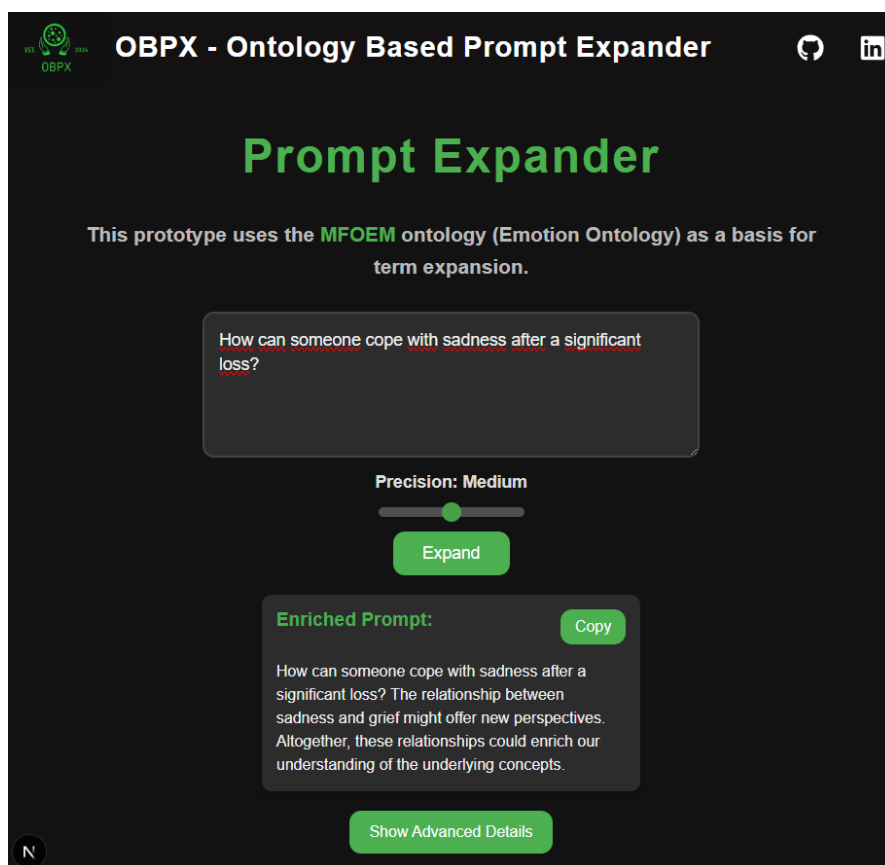
A Figura 12 apresenta a interface da documentação técnica do *back-end*, gerada com *MkDocs* a partir dos comentários em código. O material inclui especificações dos *endpoints*, exemplos de uso e instruções de configuração da API.

Figura 12 – Página inicial da documentação construída para o *back-end*.

Fonte: Autores.

4.2 *Front-end*

O front-end cumpriu seu papel como interface de interação com o usuário, fundamental para a usabilidade e acessibilidade do sistema. Desenvolvido para ser intuitivo, ele permite a entrada do *prompt* em linguagem natural e a seleção de um nível de precisão, configurando-se como o ponto de partida para a interação do usuário com a inteligência do sistema. Após o envio do *prompt* e o processamento dos dados pelo *back-end*, o *front-end* é o responsável por apresentar o *prompt* enriquecido de forma clara e objetiva, facilitando sua utilização com a opção de cópia rápida para a área de transferência, conforme ilustrado na Figura 13.

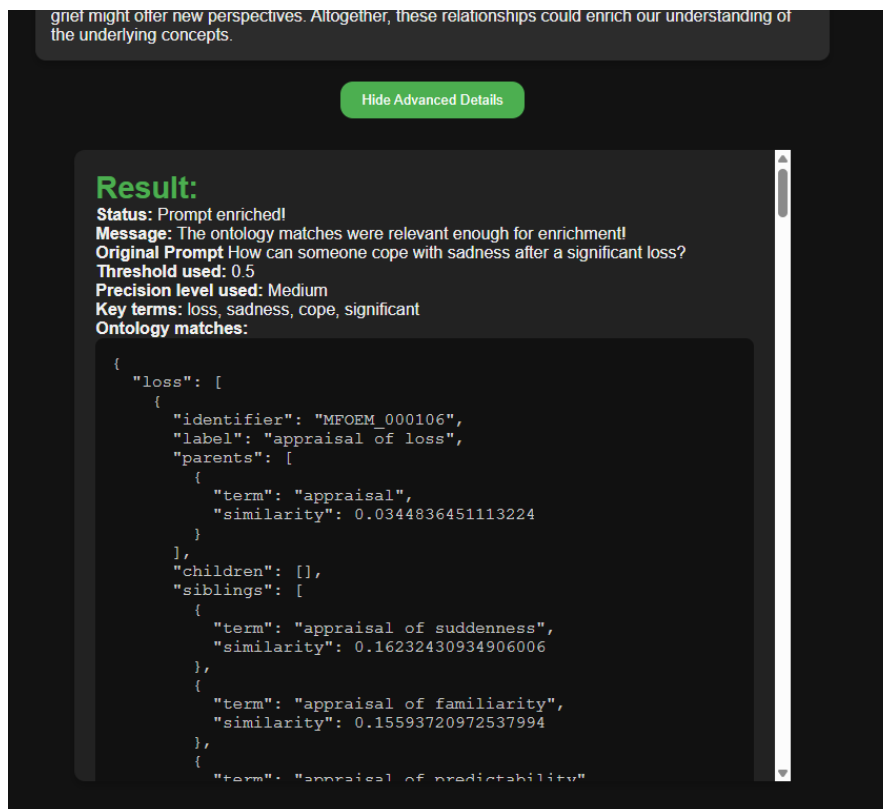
Figura 13 – Exibição do *prompt* enriquecido.

Fonte: Autores.

Para além da exibição do resultado final, a interface oferece uma camada adicional de transparência e controle para o usuário. Reconhecendo a importância da interpretabilidade em sistemas baseados em inteligência artificial, o *front-end* disponibiliza uma funcionalidade de visualização de detalhes avançados. Essa opção permite que o usuário explore os parâmetros internos que foram utilizados no processo de enriquecimento do *prompt*. Ao ativar essa visualização, são apresentadas informações cruciais, como o valor de *threshold* empregado, os termos-chave que foram extraídos do *prompt* original e, mais importante, suas correspondências exatas com os conceitos definidos na ontologia. Estes elementos visam não apenas aumentar a confiança do usuário no sistema, mas também oferecer uma compreensão aprofundada de como o conhecimento formalizado da ontologia foi aplicado para refinar e expandir a consulta inicial. A Figura 14 ilustra a

interface detalhada com essas informações.

Figura 14 – Visualização opcional de detalhes avançados.



Fonte: Autores.

O repositório em React.js para o *front-end* se encontra no Apêndice B.

4.3 Resultados dos Testes

Conforme estabelecido na Seção 3.2.5, a execução dos testes seguiu um fluxo sistemático e automatizado, aplicado a cada *prompt* da amostra. A seguir, apresenta-se um exemplo detalhado de todo o processo, utilizando como base o *prompt* referente à temática da tristeza.

1. Geração do *prompt* enriquecido pelo protótipo

A Figura 13 ilustra o resultado da aplicação do sistema de enriquecimento sobre o *prompt* original:

"How can someone cope with sadness after a significant loss?"

A versão enriquecida, gerada pelo protótipo, foi:

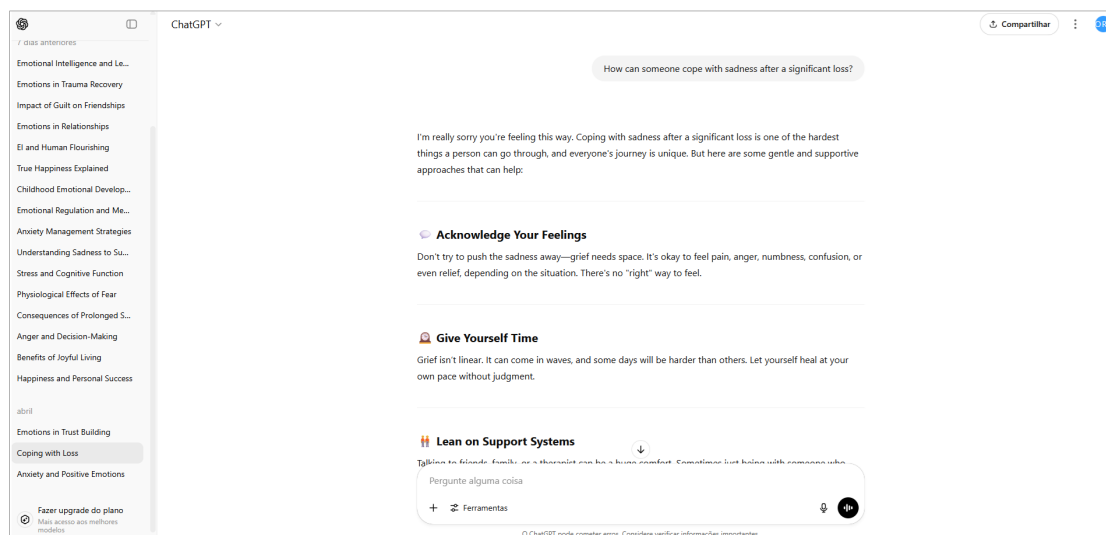
"How can someone cope with sadness after a significant loss? Exploring the link between sadness and grief, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts."

Em tradução livre: “Como alguém pode lidar com a tristeza após uma perda significativa? Explorando a ligação entre tristeza e luto, que *insights* emergem? Em conjunto, essas relações podem enriquecer nossa compreensão dos conceitos subjacentes.”

2. Envio dos *prompts* ao ChatGPT, em sessões isoladas

O *prompt* original foi enviado por meio da conta obpxrawprompts@gmail.com, conforme mostra a Figura 15:

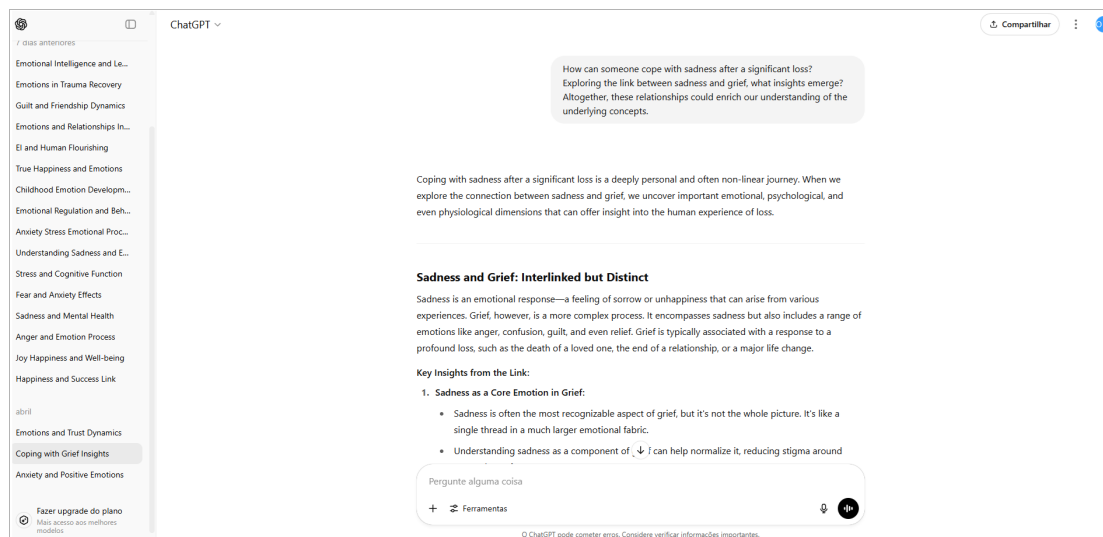
Figura 15 – Envio do *prompt* original ao ChatGPT e resposta gerada.



Fonte: Extraído da seção de configuração do ChatGPT (2025).

Em paralelo, a versão enriquecida foi submetida ao mesmo modelo, utilizando a conta `obpxexpandedprompts@gmail.com`, ilustrada na Figura 16:

Figura 16 – Envio do *prompt* expandido ao ChatGPT e resposta gerada.



Fonte: Extraído da seção de configuração do ChatGPT (2025).

3. Registro e organização das respostas

As respostas textuais fornecidas pela IA foram documentadas em uma planilha eletrônica no Google Sheets (Apêndice A). Essa organização permitiu o controle e comparação sistemática dos dados, tanto para análise qualitativa quanto quantitativa. A planilha completa está incluída em anexo ao trabalho.

4. Análise de similaridade semântica via *endpoint*

As combinações de *prompt* e resposta foram submetidas ao serviço de similaridade semântica, desenvolvido com base em SBERT e integrado ao *back-end*. A ferramenta Insomnia foi utilizada para realizar as requisições HTTP ao *endpoint* da API, como mostram as Figuras 17 e 18.

Figura 17 – Envio do *prompt* original e sua resposta à API de similaridade semântica.

POST Calculate Similarity X +	
POST http://localhost:8000/calculate_similarity	Send 200 OK 224 ms 19 B
Params Body Auth Headers 4 Scripts Docs	Preview Headers 4 Cookies
JSON	Preview
<pre> 1 { 2 "prompt": "How can someone cope with sadness after a significant loss?", 3 "gpt_response": "I'm really sorry you're feeling this way. Coping with sadness after a significant loss is one of the hardest things a person can go through, and everyone's journey is unique. But here are some gentle and supportive approaches that can help:\n\n---\n\n#### 🌱 **Acknowledge Your Feelings**\nDon't try to push the sadness away--grief needs space. It's okay to feel pain, anger, numbness, confusion, or even relief, depending on the situation. There's no \"right\" way to feel.\n\n---\n\n#### 🕒 **Give Yourself Time**\nGrief isn't linear. It can come in waves, and some days will be harder than others. Let yourself heal at your own pace without judgment.\n\n---\n\n#### 🤝 **Lean on Support Systems**\nTalking to friends, family, or a therapist can be a huge comfort. Sometimes just being with someone who listens without trying to fix it is enough.\n\n---\n\n#### 📝 **Express It**\nWriting in a journal, creating art, or simply speaking your thoughts out loud can help you process everything going on inside.\n\n---\n\n#### 🌿 **Create a Ritual**\nThis could be something small like lighting a candle, planting a tree, or revisiting a place that holds meaning. Honoring the loss in a personal way helps create a sense of connection.\n\n---\n\n#### 🏃 **Take Care of Your Body**\nGrief impacts us physically, too. Try to get rest, eat when you can, and go outside for a walk. Gentle routines can help ground you when things feel overwhelming.\n\n---\n\n#### 🧠 **Consider Professional Help**\nGrief counseling or therapy can offer a safe space to explore your feelings. You're not weak for needing support--you're human.\n\n---\n\n**If this is about something you're going through right now, I'm here to talk about it or just sit with you in it if you need.**" 4 }</pre>	<pre> 1 { 2 "similarity": 0.78 3 }</pre>

Fonte: Extraído da seção de requisições do Insomnia (2025).

Figura 18 – Envio do *prompt* expandido e sua resposta à API de similaridade semântica.

POST Calculate Similarity X +	
POST http://localhost:8000/calculate_similarity	Send 200 OK 177 ms 19 B
Params Body Auth Headers 4 Scripts Docs	Preview Headers 4 Cookies
JSON	Preview
<pre> 1 { 2 "prompt": "How can someone cope with sadness after a significant loss? Exploring the link between sadness and grief, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.", 3 "gpt_response": "Coping with sadness after a significant loss is a deeply personal and often non-linear journey. When we explore the connection between sadness and grief, we uncover important emotional, psychological, and even physiological dimensions that can offer insight into the human experience of loss.\n\n---\n\n#### **Sadness and Grief: Interlinked but Distinct**\nSadness is an emotional response--a feeling of sorrow or unhappiness that can arise from various experiences. Grief, however, is a more complex process. It encompasses sadness but also includes a range of emotions like anger, confusion, guilt, and even relief. Grief is typically associated with a response to a profound loss, such as the death of a loved one, the end of a relationship, or a major life change.\n\n---\n\n#### Key Insights from the Link:\n1. **Sadness as a Core Emotion in Grief**\n- Sadness is often the most recognizable aspect of grief, but it's not the whole picture. It's like a single thread in a much larger emotional fabric.\n- Understanding sadness as a component of grief can help normalize it, reducing stigma around expressions of sorrow.\n2. **The Grieving Process**\n- According to models like Kübler-Ross's five stages of grief (denial, anger, bargaining, depression, and acceptance), sadness tends to align most with the \"depression\" stage, but it can appear at any point.\n- Grief isn't linear--people often cycle through these emotions in unique and unpredictable ways.\n3. **Sadness as a Signal for Healing**\n- Emotionally, sadness helps signal the significance of what has been lost. It draws attention to what matters most, allowing space for reflection and, eventually, adaptation.\n- It can encourage introspection, prompting individuals to re-evaluate priorities and redefine their sense of identity after a loss.\n4. **Cultural and Social Factors**\n- How people experience and express grief and sadness is influenced by culture, upbringing, and societal norms. Some cultures encourage outward expressions, while others value stoicism.\n\n---\n\n#### **Coping Strategies for Sadness After Loss**\n1. **Acknowledge and Express**\n- Allow yourself to feel sadness without judgment. Suppressing it can prolong the grieving process.\n- Writing, talking, or creating art can be powerful ways to externalize inner emotions.\n2. **Connection and Support**\n- Reaching out to trusted friends, family, or support groups can help counteract the isolating nature of grief.\n- Professional help (like therapy) provides tools to navigate especially intense or prolonged grief.\n3. **Ritual and Remembrance**\n- Engaging in rituals (funerals, memorials, anniversaries) can offer structure and communal support.\n- Creating personal remembrance practices (journaling, planting a tree, etc.) can provide continuity and a sense of meaning.\n4. **Mindfulness and Self- care**\n- Mindful practices like meditation or breathing exercises can help calm emotional turmoil.\n- Sleep, nutrition, and physical movement also play essential roles in emotional resilience.\n\n---\n\n#### **Enriching Our Understanding**\nBy examining the interplay between sadness and grief, we gain a deeper appreciation for the complexity of emotional responses to loss. Sadness isn't a sign of weakness--it's a testament to love, attachment, and what it means to be human. Understanding this helps foster compassion--for ourselves and others--during one of life's most challenging experiences.\n\nWould you like to explore this from a philosophical, psychological, or cultural angle next?" 4 }</pre>	<pre> 1 { 2 "similarity": 0.85 3 }</pre>

Fonte: Extraído da seção de requisições do Insomnia (2025).

5. Registro dos valores de similaridade semântica

Os valores retornados pelo *endpoint* — variando entre 0 e 1, sendo 1 o grau máximo de similaridade — foram novamente registrados na planilha central de testes. No caso do exemplo apresentado, os valores obtidos foram:

- **Prompt original:** 0,78
- **Prompt enriquecido:** 0,85

6. Comparação quantitativa dos resultados

Como é possível observar, a versão enriquecida do *prompt* apresentou um ganho de 0,07 pontos na métrica de similaridade semântica, em comparação com a versão original. Este padrão se repetiu ao longo de outras instâncias da amostra de testes, como será detalhado na próxima seção (ver Seção 4.4).

Em síntese, o fluxo proposto de enriquecimento e avaliação demonstrou ser funcional e mensurável. O uso de sessões isoladas, registros padronizados e ferramentas de análise semântica permitiu capturar com precisão o impacto positivo da etapa de enriquecimento sobre a qualidade das respostas geradas por modelos de linguagem.

4.4 Análise Geral dos Resultados

Esta seção apresenta uma análise detalhada dos resultados obtidos a partir dos testes realizados, focando em como o processo de enriquecimento semântico impactou a similaridade entre os *prompts* originais e as respostas geradas por uma inteligência artificial generativa. Foram executadas avaliações sistemáticas em um conjunto de 29 amostras de *prompts* cuidadosamente selecionadas, visando compreender as nuances da interação entre a ontologia, a expansão do *prompt* e a qualidade da resposta final.

Para uma avaliação abrangente, a amostra de *prompts* foi estrategicamente dividida: 19 *prompts* foram formulados de maneira otimizada, seguindo rigorosos critérios de pontuação, semântica, capitalização e gramática, refletindo cenários de uso ideal. Em contraste, 10 *prompts* foram deliberadamente elaborados com inconsistências (como pontuações irregulares, capitalizações não padronizadas e semântica confusa), simulando desafios comuns encontrados em interações reais com sistemas de IA. Essa metodologia

permitiu uma comparação robusta do desempenho do sistema sob diferentes condições de entrada.

Os *prompts* bem formulados, tanto em suas versões originais quanto expandidas, estão detalhados na Tabela 1. Já os *prompts* mal formulados, tanto em suas versões originais quanto expandidas, estão detalhados na Tabela 2. Estas tabelas foram estruturadas em três colunas:

- **ID:** Um identificador único para cada *prompt*, facilitando a rastreabilidade e a correlação dos resultados entre as diversas análises e tabelas apresentadas no trabalho.
- **Prompt Original:** O *prompt* inicial fornecido ao sistema, formulado arbitrariamente com foco em emoções humanas, servindo como a base para o enriquecimento.
- **Prompt Expandido:** A versão do *prompt* expandida semântica e sintaticamente pelo sistema desenvolvido, utilizando o conhecimento da ontologia e as técnicas propostas para potencializar a qualidade da interação com a IA generativa.

Tabela 1 – *Prompts* bem formulados em suas formas originais e expandidas

ID	Prompt Original	Prompt Expandido
6	How does anger affect decision-making?	How does anger affect decision-making? Is anger's origin tied to emotion process? How might this matter? Moreover, the relationship between anger and negative emotion might offer new perspectives. Interestingly, anger appears to be rooted in emotion process. What foundational role does this play? Notably, exploring the link between affective process and emotion process, what insights emerge? It is also worth noting that, exploring the link between subjective affective feeling and emotion process, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
15	How does the concept of emotional intelligence relate to human flourishing?	How does the concept of emotional intelligence relate to human flourishing? emotional behavioural process might underlie emotional bodily movement behaviour. What broader implications does this have? Moreover, emotional bodily movement behaviour is influenced by emotional behavioural process. How might this affect its role? Interestingly, what role does emotional behavioural process play in shaping emotional speaking behaviour? Altogether, these relationships could enrich our understanding of the underlying concepts.
1	Is there a connection between anxiety and positive emotions?	Is there a connection between anxiety and positive emotions? emotion process may affect positive emotion. What might be the consequences? Moreover, stress (emotion) seems closely related to positive emotion. Could this be significant? Interestingly, pleasure (emotion) seems closely related to positive emotion. Could this be significant? Notably, exploring the link between anxiety and positive emotion, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.

ID	Prompt Original	Prompt Expandido
2	How can someone cope with sadness after a significant loss?	How can someone cope with sadness after a significant loss? Exploring the link between sadness and grief, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
3	What emotions are tied to building trust between two people?	What emotions are tied to building trust between two people? emotion process may affect trust. What might be the consequences? Moreover, stress (emotion) seems closely related to trust. Could this be significant? Interestingly, the relationship between pleasure (emotion) and trust might offer new perspectives. Altogether, these relationships could enrich our understanding of the underlying concepts.
4	How can happiness contribute to personal success?	How can happiness contribute to personal success? Exploring the link between happiness and satisfaction, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
5	What are the benefits of experiencing joy in daily life?	What are the benefits of experiencing joy in daily life? joy may be shaped by happiness. Could this influence its relationship with other concepts? Moreover, is joy's origin tied to happiness? How might this matter? Altogether, these relationships could enrich our understanding of the underlying concepts.
9	How does stress impact cognitive function?	How does stress impact cognitive function? Exploring the link between function and emotion disposition, what insights emerge? Moreover, stress (emotion) seems closely related to anxiety. Could this be significant? Interestingly, stress (emotion) is influenced by mental process. How might this affect its role? Notably, cognitive process may be shaped by mental process. Could this influence its relationship with other concepts? It is also worth noting that, the relationship between cognitive process and affective process might offer new perspectives. Additionally, cognitive process is influenced by mental process. How might this affect its role? Altogether, these relationships could enrich our understanding of the underlying concepts.
10	How can understanding sadness help us support others?	How can understanding sadness help us support others? sadness seems closely related to positive emotion. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.
12	What role does emotional regulation play in mental health disorders?	What role does emotional regulation play in mental health disorders? What role does emotional behavioural process play in shaping emotional speaking behaviour? Moreover, what role does emotional behavioural process play in shaping emotional speaking behaviour? Altogether, these relationships could enrich our understanding of the underlying concepts.
13	How do childhood experiences shape emotional development?	How do childhood experiences shape emotional development? emotional behavioural process might underlie emotional speaking behaviour. What broader implications does this have? Moreover, emotional speaking behaviour may be shaped by emotional behavioural process. Could this influence its relationship with other concepts? Interestingly, openness to experience seems closely related to emotional personality trait. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.
14	What does it mean to experience true happiness?	What does it mean to experience true happiness? Exploring the link between happiness and positive emotion, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
16	How do emotions shape our personal relationships?	How do emotions shape our personal relationships? Exploring the link between emotion process and positive emotion, what insights emerge? Moreover, stress (emotion) may be shaped by emotion process. Could this influence its relationship with other concepts? Interestingly, stress (emotion) seems closely related to positive emotion. Could this be significant? Notably, interpersonal disgust appears to be rooted in emotion process. What foundational role does this play? Altogether, these relationships could enrich our understanding of the underlying concepts.

ID	Prompt Original	Prompt Expandido
17	Why do feelings of guilt have such a strong impact on friendships?	Why do feelings of guilt have such a strong impact on friendships? Exploring the link between guilt and positive emotion, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
18	Which emotions are most linked to overcoming trauma?	Which emotions are most linked to overcoming trauma? emotion process seems closely related to stress (emotion). Could this be significant? Moreover, the relationship between pleasure (emotion) and stress (emotion) might offer new perspectives. Interestingly, inspiration (emotion) seems closely related to stress (emotion). Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.
19	How does emotional intelligence influence learning?	How does emotional intelligence influence learning? The relationship between learning or memory and emotional behavioural process might offer new perspectives. Moreover, learning appears to be rooted in learning or memory. What foundational role does this play? Interestingly, learning may be shaped by learning or memory. Could this influence its relationship with other concepts? Notably, exploring the link between emotional behavioural process and learning or memory, what insights emerge? It is also worth noting that, emotional bodily movement behaviour appears to be rooted in emotional behavioural process. What foundational role does this play? Additionally, emotional bodily movement behaviour is influenced by emotional behavioural process. How might this affect its role? Altogether, these relationships could enrich our understanding of the underlying concepts.
7	What are the consequences of prolonged sadness on mental health?	What are the consequences of prolonged sadness on mental health? Exploring the link between sadness and stress (emotion), what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
8	What are the physiological effects of fear on the human body?	What are the physiological effects of fear on the human body? Exploring the link between fear and anxiety, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
11	What strategies can we use to help people manage anxiety?	What strategies can we use to help people manage anxiety? anxiety seems closely related to stress (emotion). Could this be significant? Moreover, is moving towards people's origin tied to emotional behavioural process? How might this matter? Interestingly, moving away from people appears to be rooted in emotional behavioural process. What foundational role does this play? Altogether, these relationships could enrich our understanding of the underlying concepts.

Tabela 2 – Prompts mal formulados em suas formas originais e expandidas

ID	Prompt Original	Prompt Expandido
20	anxiety good or bad emotions	anxiety good or bad emotions. The relationship between anxiety and positive emotion might offer new perspectives. Moreover, emotion process seems closely related to anxiety. Could this be significant? Interestingly, exploring the link between stress (emotion) and anxiety, what insights emerge? Notably, the relationship between pleasure (emotion) and anxiety might offer new perspectives. Altogether, these relationships could enrich our understanding of the underlying concepts.
21	How get over sad when lose someone?	How get over sad when lose someone? sadness seems closely related to grief. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.
22	trust is feelings or just brain stuff?	trust is feelings or just brain stuff? trust seems closely related to jealousy. Could this be significant? Moreover, mistrust seems closely related to jealousy. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.

ID	Prompt Original	Prompt Expandido
23	Happy make success or success make happy?	Happy make success or success make happy? canonical happy facial expression is influenced by emotional behavioural process. How might this affect its role? Moreover, canonical happy voice utterance is influenced by emotional behavioural process. How might this affect its role? Altogether, these relationships could enrich our understanding of the underlying concepts.
24	Joy... is it real every day or fake sometimes?	Joy... is it real every day or fake sometimes? Exploring the link between enjoyment and joy, what insights emerge? Altogether, these relationships could enrich our understanding of the underlying concepts.
25	Angry decision brain mess?	Angry decision brain mess? canonical angry facial expression may be shaped by emotional behavioural process. Could this influence its relationship with other concepts? Moreover, canonical angry voice utterance appears to be rooted in emotional behavioural process. What foundational role does this play? Altogether, these relationships could enrich our understanding of the underlying concepts.
26	Sad too long does what in brain	Sad too long does what in brain. The relationship between sadness and stress (emotion) might offer new perspectives. Moreover, sadness is influenced by mental process. How might this affect its role? Altogether, these relationships could enrich our understanding of the underlying concepts.
27	Fear body do what? shaking	Fear body do what? shaking. fear seems closely related to anxiety. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.
28	Child times = emotions now? yes or no?	Child times = emotions now? yes or no? annoyance may be shaped by emotion process. Could this influence its relationship with other concepts? Moreover, what role does emotional behavioural process play in shaping canonical angry facial expression? Interestingly, is canonical emotional facial expression's origin tied to emotional behavioural process? How might this matter? Notably, emotion process may affect stress (emotion). What might be the consequences? It is also worth noting that, is stress (emotion)'s origin tied to emotion process? How might this matter? Additionally, stress (emotion) appears to be rooted in emotion process. What foundational role does this play? Altogether, these relationships could enrich our understanding of the underlying concepts.
29	Smart emotions = good in school?	Smart emotions = good in school? How does emotion process impact positive emotion in meaningful ways? Moreover, exploring the link between stress (emotion) and positive emotion, what insights emerge? Interestingly, pleasure (emotion) seems closely related to positive emotion. Could this be significant? Altogether, these relationships could enrich our understanding of the underlying concepts.

Os dados consolidados encontram-se na Tabela 3. Esta tabela foi organizada com seis colunas:

- **ID:** O identificador único de cada *prompt*, essencial para o processo de análise em diferentes tabelas.
- **Prompt (Original):** O *prompt* utilizado como base, gerado de forma arbitrária com relação às emoções humanas. Nesta tabela, seu papel é apenas facilitar a distinção de *prompts* para o leitor.
- **Similaridade (Original):** O valor de similaridade semântica calculado entre o *prompt* original e sua resposta recebida pela IA generativa utilizada.

- **Similaridade (Expandido):** O valor de similaridade semântica calculado entre o *prompt* expandido e sua resposta recebida pela IA generativa utilizada.
- **Resultado:** Uma definição ternária que diz se o resultado foi IGUAL, MELHOR ou PIOR comparando a similaridade do *prompt* expandido com a similaridade do *prompt* original, respectivamente.
- **Diferença:** Um número extraído da diferença entre a similaridade do *prompt* expandido com a similaridade do *prompt* original.

A coluna "Resultado" foi utilizada para ordenar as linhas da tabela por ordem alfabética, agrupando os testes de mesmo resultado.

Tabela 3 – Comparação dos resultados obtidos por *prompt*

ID	Prompt (Original)	Similaridade (Original)	Similaridade (Expandido)	Resultado	Diferença
6	How does anger affect decision-making?	0.84	0.84	IGUAL	0.00
15	How does the concept of emotional intelligence relate to human flourishing?	0.78	0.78	IGUAL	0.00
1	Is there a connection between anxiety and positive emotions?	0.8089	0.82	MELHOR	0.01
2	How can someone cope with sadness after a significant loss?	0.78	0.85	MELHOR	0.07
3	What emotions are tied to building trust between two people?	0.73	0.82	MELHOR	0.09
4	How can happiness contribute to personal success?	0.80	0.87	MELHOR	0.07
5	What are the benefits of experiencing joy in daily life?	0.78	0.86	MELHOR	0.08
9	How does stress impact cognitive function?	0.59	0.76	MELHOR	0.17
10	How can understanding sadness help us support others?	0.58	0.83	MELHOR	0.25
12	What role does emotional regulation play in mental health disorders?	0.72	0.79	MELHOR	0.07
13	How do childhood experiences shape emotional development?	0.62	0.76	MELHOR	0.14
14	What does it mean to experience true happiness?	0.76	0.80	MELHOR	0.04
16	How do emotions shape our personal relationships?	0.71	0.85	MELHOR	0.14
17	Why do feelings of guilt have such a strong impact on friendships?	0.85	0.87	MELHOR	0.02
18	Which emotions are most linked to overcoming trauma?	0.68	0.75	MELHOR	0.07
19	How does emotional intelligence influence learning?	0.72	0.79	MELHOR	0.07
20	anxiety good or bad emotions	0.62	0.77	MELHOR	0.15
21	How get over sad when lose someone?	0.65	0.75	MELHOR	0.10
22	trust is feelings or just brain stuff?	0.77	0.86	MELHOR	0.09
23	Happy make success or success make happy?	0.71	0.74	MELHOR	0.03
24	Joy... is it real every day or fake sometimes?	0.64	0.80	MELHOR	0.16
25	Angry decision brain mess?	0.68	0.81	MELHOR	0.13
26	Sad too long does what in brain	0.62	0.81	MELHOR	0.19
27	Fear body do what? shaking	0.62	0.79	MELHOR	0.17
28	Child times = emotions now? yes or no?	0.70	0.83	MELHOR	0.13
29	Smart emotions = good in school?	0.76	0.81	MELHOR	0.05
7	What are the consequences of prolonged sadness on mental health?	0.78	0.75	PIOR	-0.03
8	What are the physiological effects of fear on the human body?	0.75	0.73	PIOR	-0.02
11	What strategies can we use to help people manage anxiety?	0.78	0.73	PIOR	-0.05

De maneira geral, observou-se que a aplicação da expansão semântica foi eficaz em **82,75%** dos casos ($n = 24$), resultando em um aumento da similaridade. Em **6,9%** dos casos ($n = 2$), não houve alteração significativa nos valores de similaridade. Por fim, em **10,3%** dos exemplos ($n = 3$), a aplicação do enriquecimento resultou em decréscimo da similaridade.

A média de incremento nos casos classificados como **MELHOR** foi de aproximadamente **0,099**, enquanto a média de decréscimo nos casos **PIOR** foi de **-0,033**, indicando que os ganhos médios superaram substancialmente as perdas nos casos em que o enriquecimento não foi benéfico.

Os maiores ganhos individuais de similaridade ocorreram nos *prompts* de ID 10 (+0,25), 26 (+0,19), 27 (+0,17) e 9 (+0,17), todos com temáticas voltadas à compreensão de emoções complexas ou experiências subjetivas. Esse padrão sugere que o enriquecimento semântico é particularmente eficaz em contextos mais abstratos ou relacionais, nos quais a escolha lexical e a contextualização desempenham papel fundamental na interpretação da resposta gerada.

Por outro lado, os casos classificados como **PIOR** — IDs 7, 8 e 11 — apresentaram temáticas mais objetivas ou estruturadas, o que indica que o enriquecimento pode, nesses casos, introduzir ruídos ou desviar o foco conceitual do *prompt* original. Tais resultados sugerem a importância de se considerar o grau de clareza e especificidade dos *prompts* antes de aplicar estratégias de expansão semântica.

Em síntese, os dados apontam que a abordagem de enriquecimento baseada em técnicas de Processamento de Linguagem Natural e Ontologias possui alto potencial para aumentar a coesão semântica entre *prompts* e respostas, especialmente em contextos subjetivos. Contudo, sua aplicação deve ser criteriosa, evitando casos em que a clareza do *prompt* já é satisfatória ou excessivamente técnica.

5 Discussão

A definição do tema deste Trabalho de Conclusão de Curso exigiu semanas de reflexão e diálogo com a orientação do trabalho. A proposta inicial envolvia o uso de ontologias — um campo ainda pouco explorado no Brasil — com aplicação no contexto da saúde, alinhando-se ao crescimento das inteligências artificiais generativas e à importância da formulação eficaz de *prompts*. Um dos tópicos discutidos foi a doença pulmonar EVALI, condição observada no âmbito acadêmico entre diversos estudantes, o que motivou a investigação inicial sobre o tema. Entretanto, ao explorar o repositório de ontologias da OBO Foundry, constatou-se a ausência de ontologias que tratassem diretamente desse problema, o que ampliaria demasiadamente o escopo do trabalho. Diante disso, optou-se por um foco mais factível: investigar a relação entre ontologias, linguagem natural e engenharia de *prompt* no contexto de IAs generativas.

Ainda no período cursado do componente curricular TCC 1, uma professora especialista na criação de ontologias foi convidada a integrar a orientação do projeto. Sua expertise na área de ontologias contribuiu significativamente para o aprofundamento teórico e consolidação do referencial conceitual. Foi nesse período que a ontologia MFOEM foi identificada como uma oportunidade interessante, dado que muitas interações com IAs generativas envolvem sentimentos e emoções — exatamente o domínio da MFOEM.

A escolha da ontologia MFOEM foi também estrategicamente motivada pela natureza de seu vocabulário. Em contraste com ontologias que empregam terminologias altamente técnicas ou científicas, como aquelas encontradas em domínios biomédicos específicos, a MFOEM apresenta uma representação de fenômenos afetivos que se alinha mais com a linguagem cotidiana. Essa característica é fundamental para o propósito deste trabalho, pois o público-alvo do sistema proposto não é composto por cientistas, pesquisadores ou especialistas em áreas específicas, mas sim por pessoas comuns formulando perguntas cotidianas a IAs generativas. Termos excessivamente técnicos na ontologia poderiam dificultar a correta identificação e expansão dos *prompts*, introduzindo ruídos e comprometendo a relevância semântica dos termos enriquecidos para o usuário final e

para a IA. Portanto, a MFOEM se mostrou ideal por permitir uma expansão que é tanto semanticamente rica quanto acessível.

O processo de implementação trouxe diversos obstáculos técnicos. Inicialmente, houve grande dificuldade para realizar a leitura da ontologia em Python, o que demandou pesquisa extensa e diversas tentativas até encontrar uma abordagem viável.

Esse momento foi particularmente desafiador em termos emocionais e motivacionais. Por diversas vezes, cogitou-se adiar a continuidade do projeto, principalmente diante da sensação de insegurança quanto à viabilidade técnica do protótipo. Isso se deve ao fato de que essa etapa dependia diretamente das habilidades do primeiro autor enquanto programador. No entanto, após aproximadamente 2 meses de persistência, foi possível construir um *back-end* funcional, ainda que preliminar, que serviu como base para avançar com segurança no semestre.

A retomada das reuniões semanais com os orientadores no início do semestre foi um fator importante para o progresso do projeto. A partir desse ponto, o *front-end* foi desenvolvido, melhorias foram implementadas, e o protótipo atingiu um estágio satisfatório. Ainda assim, houve momentos de insatisfação com o desempenho do algoritmo de expansão de *prompts*, o que gerou inseguranças quanto à qualidade dos resultados. A partir da necessidade de mais qualidade semântica, foi possível refinar a metodologia, ajustar o código e alcançar um nível de sofisticação compatível com os objetivos do trabalho.

Um ponto de validação crucial da robustez do sistema foi o desempenho notável alcançado com os 10 *prompts* deliberadamente mal formulados. Apesar das inconsistências em pontuação, capitalização e semântica, o processo de enriquecimento foi capaz de transformar significativamente essas entradas, resultando em melhorias consistentes na similaridade semântica com as respostas geradas pela IA. Esse resultado é particularmente relevante, pois demonstra que o sistema proposto possui uma capacidade intrínseca de lidar e corrigir ambiguidades ou imprecisões em *prompts* iniciais, indicando sua preparação para interações com usuários que não necessariamente dominam técnicas de formulação de consultas. Tal achado valida a eficácia da abordagem em cenários de uso real, onde a qualidade da entrada do usuário pode variar consideravelmente. No entanto, é importante salientar que, devido às limitações de tempo disponível para o aprimoramento

do *back-end*, o sistema atual não dispõe de uma validação sintática robusta na entrada dos prompts. Isso significa que termos mal digitados ou erros ortográficos grosseiros não são corrigidos automaticamente pelo sistema antes do processamento, constituindo uma limitação a ser abordada em trabalhos futuros.

Durante a redação da Metodologia, surgiu uma dificuldade inesperada: um bloqueio criativo e emocional, relacionado à memória dos momentos de maior desafio vividos nos primeiros meses do ano. Retomar esses acontecimentos exigiu certo esforço psicológico, mas, ao dar início à escrita, o processo fluiu com naturalidade, permitindo o avanço contínuo na elaboração do texto.

Além dos desafios de implementação, a publicação do sistema em ambiente de produção também enfrentou limitações práticas. Apesar de o protótipo estar disponível online¹, mantê-lo em funcionamento contínuo revelou-se inviável. Isso ocorreu por dois motivos principais: primeiro, o custo variável da hospedagem do *back-end* na plataforma Railway², que, mesmo em seu plano mais básico (Hobby), estimava cobranças mensais acima de 100 dólares para um uso mínimo da API; segundo, as restrições técnicas do plano gratuito, que impedia o deploy devido ao limite de imagem de 4 GB, sendo que o projeto exige mais de 7 GB devido ao uso de modelos e bibliotecas de linguagem natural. Tais fatores inviabilizaram o funcionamento estável e contínuo do sistema, embora sua estrutura e desempenho tenham sido validados localmente.

Este trabalho representou não apenas um exercício acadêmico, mas também uma jornada de amadurecimento pessoal e profissional. Conduzir um projeto de escopo reduzido, porém de alta complexidade técnica e conceitual, demandou habilidades de pesquisa, autogestão e resiliência — elementos que certamente acompanharão o autor em desafios futuros.

¹ <https://prompt-enricher-frontend.vercel.app/>. Acessado em 31/05/2025.

² <https://railway.app/>. Acessado em: 31/05/2025.

6 Conclusão

Este trabalho investigou a aplicação de técnicas de Processamento de Linguagem Natural (PLN) e ontologias para o enriquecimento de *prompts* em sistemas de IA generativa, com o objetivo de melhorar a qualidade das interações homem-máquina. Os resultados obtidos demonstraram a viabilidade da abordagem proposta, com ganhos mensuráveis na similaridade semântica entre *prompts* e respostas em 82,75% dos casos testados.

Entre as principais contribuições deste estudo, destacam-se os avanços nos campos técnico, metodológico e teórico. No aspecto técnico, foi desenvolvido um protótipo funcional que integra PLN, expansão de *queries* e consulta a ontologias para enriquecimento automático de *prompts*. A arquitetura modular implementada mostrou-se robusta e capaz de processar consultas em tempo real, conforme apresentado nas figuras que detalham o fluxo e a estrutura do *back-end*. Do ponto de vista metodológico, propôs-se um fluxo sistemático para avaliação da qualidade de *prompts*, baseado em métricas de similaridade semântica extraídas por meio do modelo SBERT. Essa abordagem permitiu quantificar de forma objetiva os ganhos proporcionados pelo enriquecimento semântico. Já no campo teórico, consolidaram-se evidências sobre a eficácia da combinação entre ontologias e PLN na engenharia de *prompt*, especialmente em contextos subjetivos e relacionais, como indicado na análise dos resultados. Os dados sugerem que a técnica é particularmente útil quando o *prompt* envolve conceitos abstratos ou emocionalmente carregados.

Apesar dos resultados promissores, o projeto enfrentou algumas limitações importantes. A principal delas foi a dependência de uma única ontologia, a MFOEM, o que restringiu o escopo de aplicação aos domínios relacionados a emoções e sentimentos. Além disso, observou-se que em 10,3% dos casos testados o enriquecimento semântico levou a uma redução da similaridade, indicando que a técnica pode gerar ruídos em *prompts* já bem formulados ou excessivamente técnicos. Nesse sentido, a escolha da ontologia é crucial, pois ontologias que empregam termos excessivamente técnicos ou especializados podem dificultar a compreensão e a eficácia da expansão para um público

leigo, que não possui conhecimento técnico aprofundado do domínio. Do ponto de vista técnico, a manipulação e processamento de ontologias em Python se mostrou desafiadora, exigindo tempo e ajustes que impactaram o cronograma inicialmente previsto.

Considerando os aprendizados obtidos ao longo do desenvolvimento, algumas direções se apresentam como promissoras para trabalhos futuros: a expansão do sistema para suportar múltiplas ontologias permitiria sua aplicação em diversos domínios de conhecimento, aumentando sua abrangência. O algoritmo desenvolvido já se encontra generalizado para ontologias que seguem os princípios da BFO (*Basic Formal Ontology*), o que favorece sua integração com diversas ontologias biomédicas da OBO Foundry. No entanto, a utilização de ontologias no formato OWL apresentou limitações práticas, como a complexidade no carregamento, alto consumo de memória e desafios na navegação dos axiomas em tempo de execução, o que sugere a necessidade de formatos mais leves ou intermediários para aplicações em produção. Além disso, emerge uma questão relevante para investigações futuras: *a forma como uma ontologia representa seu domínio pode influenciar diretamente a eficácia do enriquecimento semântico?* Essa hipótese abre caminho para estudos comparativos entre diferentes modelos ontológicos aplicados ao mesmo conjunto de *prompts*. Outras direções incluem a implementação de mecanismos de classificação automática que identifiquem quando um *prompt* se beneficiaria do enriquecimento semântico, tornando o sistema mais eficiente e preciso. Também se destacam como relevantes a investigação de técnicas mais avançadas de alinhamento semântico entre ontologias e modelos de linguagem, e a realização de testes com usuários reais, visando avaliar a percepção subjetiva da qualidade das respostas geradas.

Em termos gerais, este trabalho representou uma jornada significativa de aprendizado técnico e amadurecimento acadêmico. Desde a definição inicial do problema até a superação dos desafios práticos da implementação, cada etapa contribuiu para consolidar o potencial da integração entre ontologias e PLN como estratégia para aprimorar a interação com sistemas de IA generativa. Os resultados obtidos validam a hipótese central de que a estruturação semântica de *prompts* pode melhorar significativamente a qualidade das respostas geradas, especialmente em contextos que exigem clareza, nuance e precisão. Com isso, a pesquisa contribui para o campo emergente da engenharia de *prompt*, abrindo caminho para futuras investigações que tornem as interações homem-máquina cada vez mais naturais, eficazes e centradas no usuário.

Referências

- S. Alhasnawi, H. H. Uysal, and B. Selvi. English as the academic lingua franca (elfa) for research writing and publications. *Journal of English as a Lingua Franca*, 12 (1):1–24, 2023. URL <https://www.degruyter.com/document/doi/10.1515/jelf-2023-2014/html?lang=en>. 28
- M. B. Almeida. *Uma abordagem integrada sobre ontologias: Ciência da Informação, Ciência da Computação e Filosofia*. Editora UFMG, Belo Horizonte, MG, 2014. 16, 20
- M. B. Almeida. *Ontologia em Ciência da Informação: Teoria e Método*, volume 01 of *Coleção Representação do Conhecimento em Ciência da Informação*. Editora CRV, 1 edition, 2020. doi: 10.24824/978655578679.8. URL <https://doi.org/10.24824/978655578679.8>. 4, 15
- M. B. Almeida and E. R. Felipe. The queries expansion on biomedical terminologies: Toward a comparison of knowledge representation artifacts for information retrieval. *Trends in Technical & Scientific Research*, 1, 2021. 22, 23
- H. K. Azad and A. Deepak. Query expansion techniques for information retrieval: A survey. *Information Processing & Management*, 56(5):1698–1735, 2019. doi: 10.1016/j.ipm.2019.05.009. 22
- R. Baeza-Yates and B. Ribeiro-Neto. *Modern Information Retrieval: The Concepts and Technology Behind Search*. Addison-Wesley, 2 edition, 2011. 21
- E. M. Bender, T. Gebru, A. McMillan-Major, and S. Shmitchell. On the dangers of stochastic parrots: Can language models be too big? In *Proceedings of the 2021 ACM Conference on Fairness, Accountability, and Transparency (FAccT)*, pages 610–623. Association for Computing Machinery, 2021. 10
- T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal, A. Neelakantan, P. Shyam, G. Sastry, A. Askell, S. Agarwal, A. Herbert-Voss, G. Krueger, T. Henighan,

- R. Child, A. Ramesh, D. M. Ziegler, J. Wu, C. Winter, C. Hesse, M. Chen, E. Sigler, M. Litwin, S. Gray, B. Chess, J. Clark, C. Berner, S. McCandlish, A. Radford, I. Sutskever, and D. Amodei. Language models are few-shot learners. *arXiv preprint arXiv:2005.14165*, 2020. 9, 11, 13
- S. K. Card, T. P. Moran, and A. Newell. *The Psychology of Human-Computer Interaction*. Lawrence Erlbaum Associates, 1983. 6
- O. F. Consortium. Obo foundry - home, 2024. URL <http://www.obofoundry.org>. 19
- A. Dillon. User-centered design: A theoretical framework for the field. In *Annual Review of Information Science and Technology*, volume 37, pages 21–61. Information Today, 2002. 7
- I. Facebook and I. Meta Platforms. React – a javascript library for building user interfaces. <https://reactjs.org/>, 2025. 40
- F. Farinelli. *Ontologias de Alto Nível: por que precisamos e como usar*. Revista Fronteiras da Representação do Conhecimento, 2020. 15, 16, 17, 20
- F. Farinelli. Ontologias e linguística: uma relação que fortalece a representação do conhecimento. *Revista Fronteiras da Representação do Conhecimento*, 2021. 18
- E. A. Feigenbaum. *The Art of Artificial Intelligence: Themes and Case Studies of Knowledge Engineering*. Stanford University Press, 1977. 8
- E. R. Felipe. A expansão de queries sobre terminologias biomédicas: Uma comparação de artefatos de representação do conhecimento para recuperação de informações. *ESCOLA DE CIÊNCIA DA INFORMAÇÃO*, 2020. Seção 3.1.2: Ontologias. 16
- R. T. Fielding. *Architectural Styles and the Design of Network-Based Software Architectures*. PhD thesis, University of California, Irvine, 2000. URL <https://www.ics.uci.edu/~fielding/pubs/dissertation/top.htm>. 33
- A. for Computing Machinery. Submitting articles to acm journals. <https://www.acm.org/publications/authors/submissions>, 2025. 28
- O. Foundry. Mfoem: Emotion ontology. <https://obofoundry.org/ontology/mfoem.html>, 2024. OBO Foundry repository metadata. 38

I. Goodfellow, J. Pouget-Abadie, M. Mirza, B. Xu, D. Warde-Farley, S. Ozair, A. Courville, and Y. Bengio. Generative adversarial nets. In *Proceedings of the 27th International Conference on Neural Information Processing Systems (NIPS)*, pages 2672–2680. MIT Press, 2014. 9

M. D. Gordin. English has the scientific edge – for now. *Axios*, 2018a. URL <https://www.axios.com/2018/11/01/english-chinese-language-science-technology>. 28

M. D. Gordin. The dangers of english as lingua franca of journals. *Inside Higher Ed*, 2018b. URL <https://www.insidehighered.com/views/2018/03/13/domination-english-language-journal-publishing-hurting-scholarship-many-countries>. 28

J. Hastings, B. Smith, K. Mulligan, A. Wright, P. Schenk, R. West, and M. Braun. Mfoem (*Emotion Ontology*). <https://ontobee.org/ontology/MFOEM>, 2025. Ontology of affective phenomena, accessed 2025-05-03. 38

M. Honnibal and I. Montani. spacy — industrial-strength natural language processing in python. <https://spacy.io>, 2020. 33

M. Horridge, H. Knublauch, A. Rector, R. Stevens, and C. Wroe. *A Practical Guide to Building OWL Ontologies Using Protégé 4 and CO-ODE Tools Edition 1.3*. The University of Manchester, 2011. 19

R. Icons. Include popular icons in your react projects easily. <https://react-icons.github.io/react-icons/>, 2025. 40

U. Instituto de Informática. Call for papers – ontobras 2024. <https://www.inf.ufrgs.br/ontobras/en/call-for-papers-ontobras-2024/>, 2024. 28

D. Jurafsky and J. H. Martin. *Speech and Language Processing*. Prentice Hall, 3 edition, 2020. 13

G. Klyne and J. J. Carroll. *Resource Description Framework (RDF): Concepts and Abstract Syntax*. W3C Recommendation, 2004. URL <https://www.w3.org/TR/rdf-concepts/>. 19

- J.-B. Lamy. Owlready: Ontology-oriented programming in python with automatic classification and high level constructs for biomedical ontologies. *Artificial Intelligence in Medicine*, 80:11–28, 2017. 33
- Y. Li. A practical survey on zero-shot prompt design for in-context learning. *arXiv*, sep 2023. doi: 10.48550/arXiv.2309.13205. Available at: <https://doi.org/10.48550/arXiv.2309.13205>. 11
- I. S. MacKenzie. *Human-Computer Interaction: An Empirical Research Perspective*. Elsevier, 2024. 1
- C. D. Manning and H. Schütze. *Foundations of Statistical Natural Language Processing*. MIT Press, 1999. 14
- C. D. Manning, P. Raghavan, and H. Schütze. *Introduction to Information Retrieval*. Cambridge University Press, 2008. 21
- F. Manola and E. Miller. *RDF Primer*, 2004. URL <https://www.w3.org/TR/rdf-primer/>. W3C Recommendation. 19
- R. C. Martin. *Agile Software Development: Principles, Patterns, and Practices*. Prentice Hall, 2002. 32, 33
- J. McCarthy. *Artificial Intelligence: A Philosophical Introduction*. Stanford University Press, 2006. 9
- P. Morville and L. Rosenfeld. *Information Architecture for the World Wide Web: Designing Large-Scale Web Sites*. O’Reilly Media, 3 edition, 2005. 7
- N. Mungoli. Exploring the synergy of prompt engineering and reinforcement learning for enhanced control and responsiveness in chat gpt. *Journal of Electrical Electronics Engineering*, 2(3), julho 2023. URL <https://doi.org/10.33140/JEEE.02.03.02.1,2>
- D. Nadeau and S. Sekine. A survey of named entity recognition and classification. *Linguisticae Investigationes*, 30(1):3–26, 2007. 14
- J. Nielsen. *Usability Engineering*. Morgan Kaufmann, 1994. 7

- D. A. Norman. *The Design of Everyday Things*. Basic Books, 1988. 6
- J. C. R. D. Oliveira Jr and A. S. El Khatib. Homem ou máquina? um estudo exploratório do desempenho do chat gpt 3.5 no exame de suficiência do cfc. *Revista Capital Científico - Eletrônica*, 22(1), 2024. URL <https://doi.org/10.5935/2177-4153.20240003.2>
- OpenAI. Chatgpt: Applications and implications, 2022. URL <https://openai.com/research/chatgpt.1>
- G. d. Othero and S. d. M. Menuzzi. *Linguística Computacional: Teoria e Prática*. Parábola Editorial, São Paulo, Brasil, 2005. 18
- Project Management Institute. *A Guide to the Project Management Body of Knowledge (PMBOK Guide)*. Project Management Institute, Newton Square, PA, USA, 7th edition, 2021. 25
- N. Reimers and I. Gurevych. Sentence-bert: Sentence embeddings using siamese bert-networks. <https://arxiv.org/abs/1908.10084>, 2019. 33
- L. Reynolds and K. McDonell. Prompt programming for large language models: Beyond few-shot learning. *arXiv preprint arXiv:2102.07350*, 2021. 10, 11
- L. Rosenfeld, P. Morville, and J. Arango. *Information Architecture: For the Web and Beyond*. O'Reilly Media, 4 edition, 2015. 7
- S. Russell and P. Norvig. *Artificial Intelligence: A Modern Approach*. Pearson, 3rd edition, 2016. 9
- G. Salton and C. T. Yu. On the construction of effective vocabularies for information retrieval. *ACM SIGPLAN Notices*, 10(1):48–60, 1975. doi: 10.1145/951787.951766. 21, 22
- D. Science. In the spotlight: English as the lingua franca in science. <https://www.digital-science.com/tldr/article/in-the-spotlight-english-as-the-lingua-franca-in-science/>, 2023. 28
- ScienceDirect. Lingua franca – an overview. <https://www.sciencedirect.com/topics/computer-science/lingua-franca>, 2025. 28

- B. Shneiderman. *Designing the User Interface: Strategies for Effective Human-Computer Interaction*. Addison-Wesley, 5 edition, 2010. 6
- B. Smith. The basic formal ontology and beyond. *Applied Ontology*, 1:19–25, 2005. 20
- B. Smith and P. Grenon. The cornucopia of formal-ontological relations. *Dialectica*, 58 (3):279–296, 2004. 15, 17
- SNOMED International. The SNOMED CT Clinical Terminology, 2024. URL <https://www.snomed.org/what-is-snomed-ct>. 17
- S. Staab and R. Studer. *Handbook on Ontologies*. Springer Berlin Heidelberg, Berlin, Heidelberg, 2009. URL <https://doi.org/10.1007/978-3-540-92673-3>. 4
- A. M. Turing. Computing machinery and intelligence. *Mind*, LIX(236):433–460, October 1950. doi: 10.1093/mind/LIX.236.433. URL <https://doi.org/10.1093/mind/LIX.236.433>. 1, 8
- UFRGS. Ontobras 2025: 18th seminar on ontology research in brazil – submission guidelines. <https://easychair.org/cfp/ontobras2025>, 2025. 28
- A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin. Attention is all you need. In *Proceedings of the 31st Conference on Neural Information Processing Systems (NIPS)*, pages 6000–6010. MIT Press, 2017. 9
- I. Vercel. Next.js image component. <https://nextjs.org/docs/api-reference/next/image>, 2025a. 42
- I. Vercel. Next.js – the react framework. <https://nextjs.org/>, 2025b. 40
- T. Wolf, L. Debut, V. Sanh, J. Chaumond, and et al. Transformers: State-of-the-art natural language processing. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*, pages 38–45, 2020. 34
- A. Zivaljevic, K. Atalag, and J. Warren. Utility of snomed ct in automated expansion of clinical terms in discharge summaries: Testing issues of coverage. *Health Information Management Journal*, 2020. doi: 10.1177/1833358320934528. 22, 23

Apêndices

APÊNDICE A – Planilha de Dados dos Testes de Similaridade Semântica

Os dados completos dos testes realizados, incluindo os valores de similaridade para *prompts* brutos e enriquecidos, estão disponíveis em:

- Link para o Google Sheets disponível em https://docs.google.com/spreadsheets/d/1vYZDGOj9h74DVyBTzps4R_FCmf7nj4qHrFs6NT-M7A/edit?usp=sharing

APÊNDICE B – Repositórios do Projeto no GitHub

Os códigos-fonte desenvolvidos para este trabalho estão disponíveis publicamente em dois repositórios no GitHub, organizados em uma arquitetura de *front-end* e *back-end*:

Repositório do Back-end

- **URL:** <https://github.com/PradoPHA/prompt-enricher-backend>
- **Tecnologias:** Python 3.11, FastAPI, OWLReady2, spaCy, Sentence-Transformers
- **Descrição:** Contém a implementação do servidor responsável por:
 - Processamento de linguagem natural (PLN) dos *prompts*
 - Consulta à ontologia MFOEM
 - Expansão semântica das consultas
 - Cálculo de similaridade textual
 - API REST para integração com o *front-end*

Repositório do Front-end

- **URL:** <https://github.com/PradoPHA/prompt-enricher-frontend>
- **Tecnologias:** React.js, TypeScript, Chakra UI
- **Descrição:** Implementa a interface gráfica do usuário com:
 - Campo para inserção do *prompt* original
 - Controle para ajuste do nível de precisão

- Visualização do *prompt* enriquecido
- Modo detalhado com informações de processamento
- Integração com a API do *back-end*

Licença e Considerações

- Ambos os repositórios utilizam a licença MIT
- Contêm *README.md* com instruções de instalação e uso
- Mantêm histórico completo de commits durante o desenvolvimento do TCC